

BỘ GIÁO DỤC VÀ ĐÀO TẠO
TRƯỜNG ĐẠI HỌC MỞ THÀNH PHỐ HỒ CHÍ MINH
KHOA KHOA HỌC CƠ BẢN

-----***-----



BÀI TIỂU LUẬN
ĐỀ TÀI: PHÂN TÍCH VÀ DỰ ĐOÁN GIAN LẬN
TÀI CHÍNH BẰNG CÁC MÔ HÌNH
MACHINE LEARNING

Giảng viên hướng dẫn: Hà Minh Tuấn

Môn: Máy học

Sinh viên: Tạ Chí Bình - 2351060002

Phan Tấn Phúc - 2351060029

Phạm Nguyễn Bảo Vi - 2351060041

Lớp: DH23DS01

TP.HCM, tháng 01 năm 2026

LỜI CẢM ƠN

Trước hết, nhóm chúng em xin bày tỏ lòng biết ơn sâu sắc đến thầy Hà Minh Tuấn, giảng viên môn Máy học, thuộc Khoa Khoa học Cơ bản – Trường Đại học Mở Thành phố Hồ Chí Minh, người đã trực tiếp giảng dạy, hướng dẫn và định hướng khoa học cho chúng em trong suốt quá trình học tập và thực hiện đề tài.

Thông qua môn học, thầy đã cung cấp cho chúng em những kiến thức nền tảng và chuyên sâu về Machine Learning, đặc biệt là tư duy tiếp cận bài toán dữ liệu thực tế, cách lựa chọn mô hình phù hợp, cũng như các vấn đề quan trọng như dữ liệu mất cân bằng, đánh giá mô hình và khả năng tổng quát hóa. Những kiến thức và góp ý của thầy là cơ sở quan trọng giúp nhóm chúng em hoàn thiện đề tài Ứng dụng Machine Learning trong phát hiện gian lận tín dụng.

Nhóm chúng em cũng xin chân thành cảm ơn Khoa Khoa học Cơ bản – Trường Đại học Mở Thành phố Hồ Chí Minh đã tạo điều kiện thuận lợi về môi trường học tập, tài liệu tham khảo và cơ sở vật chất để chúng em có thể nghiên cứu và hoàn thành bài tiểu luận này.

Bên cạnh đó, nhóm xin gửi lời cảm ơn đến các tác giả của các công trình nghiên cứu khoa học trong và ngoài nước, cũng như các nguồn dữ liệu công khai, đặc biệt là nền tảng Kaggle, đã cung cấp tập dữ liệu PaySim và các tài liệu liên quan, giúp nhóm có cơ hội tiếp cận và thực hành trên một bài toán gần với thực tế của lĩnh vực tài chính – ngân hàng.

LỜI CAM KẾT

Nhóm chúng em xin cam kết rằng toàn bộ nội dung của tiểu luận “Phân tích và dự đoán gian lận tài chính bằng các mô hình Machine Learning” là kết quả của quá trình nghiên cứu, học tập và thực hiện nghiêm túc của chính nhóm, dưới sự hướng dẫn của giảng viên phụ trách môn học.

Tất cả các nội dung lý thuyết, phương pháp nghiên cứu, mô tả dữ liệu, quá trình xây dựng mô hình, kết quả thực nghiệm và phần nhận xét, đánh giá trong báo cáo đều được trình bày một cách trung thực, khách quan và dựa trên các tài liệu khoa học có nguồn gốc rõ ràng. Các tài liệu tham khảo, bài báo khoa học và nguồn dữ liệu được sử dụng trong quá trình thực hiện đề tài đều được trích dẫn đầy đủ và đúng quy định.

Tập dữ liệu sử dụng trong đề tài được nhóm thu thập từ nguồn chính thống trên Kaggle (PaySim – A Financial Mobile Money Simulator), phục vụ cho mục đích học tập và nghiên cứu khoa học, không vi phạm bản quyền hay các quy định về sử dụng dữ liệu. Các kết quả phân tích và đánh giá mô hình trong báo cáo được xây dựng dựa trên quá trình xử lý dữ liệu và thực nghiệm thực tế, không chỉnh sửa hay làm sai lệch kết quả nhằm đạt mục đích cá nhân.

Nhóm chúng em xin hoàn toàn chịu trách nhiệm trước giảng viên hướng dẫn, Khoa Khoa học Cơ bản và Trường Đại học Mở Thành phố Hồ Chí Minh về tính trung thực, chính xác và khoa học của toàn bộ nội dung tiểu luận này.

TP.HCM, ngày 01 tháng 01 năm 2026

Sinh viên

Tạ Chi Bình

Phan Tấn Phúc

Phạm Nguyễn Bảo Vi

Mục lục

1	CHƯƠNG 1: TỔNG QUAN	5
1.1	Lý do chọn đề tài	5
1.2	Mục tiêu đề tài	5
1.3	Phạm vi và giới hạn của đề tài	5
1.4	Phương pháp nghiên cứu	6
1.5	Giới thiệu về nhóm và Quy trình quản lý chất lượng	6
2	CHƯƠNG 2: DỮ LIỆU VÀ PHÂN TÍCH KHÁM PHÁ (EDA)	8
2.1	Giới thiệu tập dữ liệu PAYSIM	8
2.2	Ý nghĩa và phạm vi giá trị của các biến	9
2.3	Phân tích và khám phá dữ liệu (Exploratory Data Analysis)	10
2.3.1	Kiểm tra chất lượng dữ liệu và giá trị thiếu và bản ghi trùng lặp	10
2.3.2	Phân bố nhân gian lận và hàm ý đối với đánh giá mô hình	10
2.3.3	Phân tích loại hình gian lận và mối liên hệ với gian lận	11
2.3.4	Phân tích giá trị giao dịch và vai trò trong nhận diện gian lận	12
2.3.5	Phân tích bất thường số dư và mối liên hệ với gian lận	14
2.3.6	Phân tích mối liên hệ giữa chuỗi giao dịch chuyển tiền và rút tiền trong các giao dịch gian lận.	15
2.3.7	Phân tích tài khoản nguồn và đích trong các giao dịch gian lận.	15
2.3.8	Phân tích trạng thái không đủ số dư của người gửi trong giao dịch gian lận	16
2.3.9	Phân tích yếu tố thời gian theo ngày và giờ trong giao dịch.	16
2.3.10	Phân tích ma trận tương quan giữa các đặc trưng	17
3	CHƯƠNG 3: CƠ SỞ LÝ THUYẾT VÀ LỰA CHỌN MÔ HÌNH	18
3.1	Đặc thù bài toán gian lận tín dụng và yêu cầu đối với mô hình	18
3.2	Các chỉ số đánh giá trong bài toán phân loại mất cân bằng	19
3.3	Lựa chọn các mô hình nghiên cứu	20
3.4	HỒI QUY LOGISTIC (LOGISTIC REGRESSION)	21
3.5	RANDOM FOREST	22
3.6	EXTREME GRADIENT BOOSTING (XGBOOST)	23
3.7	So sánh tổng quan ba mô hình dưới góc nhìn xác suất và hiệu năng	24
4	CHƯƠNG 4: THIẾT KẾ THỰC NGHIỆM VÀ XÂY DỰNG MÔ HÌNH	25
4.1	Tiền xử lý dữ liệu (Feature Engineering)	25
4.1.1	Phương pháp luận – Cơ sở thiết kế đặc trưng (Feature Design Rationale)	25
4.1.2	Tính phù hợp của đặc trưng đối với mô hình	26
4.1.3	Loại bỏ các biến định danh không mang thông tin hành vi	26
4.1.4	Đánh giá và loại bỏ rò rỉ dữ liệu (Data Leakage Assessment)	27
4.2	Xây dựng và đánh giá mô hình Logistic Regression	28
4.2.1	Quy trình xây dựng mô hình	28
4.2.2	Lựa chọn và loại bỏ các đặc trưng đầu vào	28
4.2.3	Chia dữ liệu huấn luyện và kiểm tra	29
4.2.4	Huấn luyện mô hình Logistic Regression cơ sở	29
4.2.5	Kết quả đánh giá mô hình cơ sở	29
4.3	Tối ưu hóa mô hình: Resampling và điều chỉnh ngưỡng phân loại	29
4.3.1	Đánh giá các phương pháp xử lý mất cân bằng	30
4.3.2	Phân tích sâu ảnh hưởng của SMOTE-ENN	30
4.3.3	Kết luận và đề xuất triển khai	31

4.3.4	Top 10 đặc trưng quan trọng nhất	31
4.3.5	Phân tích theo nhóm đặc trưng	32
4.3.6	So sánh hệ số trước và sau Resampling	32
4.3.7	Diễn giải nghiệp vụ và đề xuất	33
4.3.8	Tổng kết Logistic Regression	34
4.4	Xây dựng và đánh giá mô hình Random Forest	34
4.4.1	Quy trình thực nghiệm tổng quát	34
4.4.2	Thiết lập mô hình Random Forest	34
4.4.3	Kết quả mô hình Random Forest cơ sở	35
4.4.4	Phân tích đặc trưng quan trọng	35
4.4.5	Xử lý mất cân bằng dữ liệu bằng Resampling	35
4.4.6	Tối ưu siêu tham số bằng Optuna	36
4.4.7	Tối ưu ngưỡng phân loại	36
4.4.8	Kết quả mô hình Random Forest cuối cùng	36
4.4.9	So sánh với Baseline	37
4.4.10	Phân tích đặc trưng quan trọng của mô hình cuối cùng	37
4.4.11	Kết luận về mô hình Random Forest	37
4.5	XÂY DỰNG VÀ ĐÁNH GIÁ MÔ HÌNH XGBOOST	37
4.5.1	Quy trình thực nghiệm tổng quát	37
4.5.2	Thiết lập mô hình XGBoost	38
4.5.3	Kết quả mô hình XGBoost cơ sở	38
4.5.4	Tối ưu siêu tham số bằng Optuna	39
4.5.5	Thử nghiệm các chiến lược resampling	39
4.5.6	Huấn luyện mô hình XGBoost cuối cùng	40
4.5.7	Tối ưu ngưỡng phân loại	40
4.5.8	Phân tích đặc trưng quan trọng	40
4.5.9	Kết quả thực nghiệm chi tiết với số liệu từ nghiên cứu	41
4.5.10	Tổng kết mô hình XGBoost	42
4.6	Dự đoán trên dữ liệu mới và mô phỏng triển khai mô hình	42
4.6.1	Mục tiêu và tập dữ liệu dự đoán	42
4.6.2	Quy trình dự đoán (Prediction Pipeline)	43
4.6.3	Kết quả dự đoán và phân tích	43
4.6.4	Nhận xét và hàm ý triển khai	45
5	CHƯƠNG 5. KẾT QUẢ THỰC NGHIỆM VÀ ĐÁNH GIÁ MÔ HÌNH	45
5.1	Phân tích kết quả thực nghiệm từng mô hình	45
5.1.1	Mô hình Logistic Regression: Nền tảng phân tách tuyến tính	45
5.1.2	Mô hình Random Forest: Khai thác quan hệ phi tuyến và tương tác đặc trưng	46
5.1.3	Mô hình XGBoost: Tối ưu hiệu năng với Gradient Boosting	47
5.2	So sánh định lượng và phân tích hiệu năng tổng thể	47
5.3	Đánh giá ảnh hưởng của ngưỡng phân lớp và bàn luận	48
5.4	Kết luận chương và khuyến nghị	49
6	CHƯƠNG 6. KẾT LUẬN	49
6.1	Tổng kết	49
6.2	Hạn chế	50
6.3	Hướng phát triển	50

Danh sách hình vẽ

2.1	Mức độ đầy đủ dữ liệu theo từng thuộc tính (missingness overview).	10
2.2	Phân bố nhãn gian lận (isFraud).	11
2.3	Phân bố giao dịch theo loại hình giao dịch (type) và nhãn gian lận (isFraud).	12
2.4	Phân bố giá trị giao dịch (amount) theo nhãn gian lận, biểu diễn bằng boxplot trên thang log.	13
2.5	Phân bố mật độ giá trị giao dịch (amount) theo nhãn gian lận, biểu diễn bằng histogram trên thang log.	13
2.6	Phân bố sai số cân bằng số dư của người gửi theo nhãn gian lận.	14
2.7	Phân bố sai số cân bằng số dư của người nhận theo nhãn gian lận.	15
2.8	Phân bố giao dịch gian lận theo ngày và giờ.	17
2.9	Ma trận tương quan giữa các đặc trưng	18
4.1	Kết quả đánh giá mô hình cơ sở	29
4.2	So sánh kết quả Logistic Regression trước và sau resampling	33
4.3	Kết quả đánh giá mô hình XGBoost cơ sở	39
4.4	Kết quả tối ưu siêu tham số bằng Optuna	39
4.5	Kết quả mô hình XGBoost tối ưu	40
4.6	Tỷ lệ giao dịch được mô hình XGBoost gắn cờ gian lận trên tập dữ liệu dự đoán mới.	44
4.7	Phân phối xác suất gian lận do mô hình XGBoost dự đoán trên dữ liệu mới.	45

Danh sách bảng

1	Đánh giá rò rỉ dữ liệu và quyết định lựa chọn đặc trưng	27
2	So sánh hiệu suất của các phương pháp resampling trên Logistic Regression	30
3	Phân tích ảnh hưởng của SMOTE-ENN đến hiệu suất và confusion matrix	30
4	Top 10 đặc trưng quan trọng nhất - Logistic Regression với SMOTE-ENN	32
5	So sánh hệ số đặc trưng trước/sau resampling	32
6	Top 6 đặc trưng quan trọng nhất của Random Forest cơ sở	35
7	Kết quả mô hình Random Forest cuối cùng	36
8	So sánh mô hình Random Forest cuối cùng với baseline	37
9	Top 5 đặc trưng quan trọng nhất của mô hình Random Forest cuối cùng	37
10	Kết quả mô hình XGBoost cơ sở	41
11	Hiệu suất các phương pháp resampling cho XGBoost	41
12	Ảnh hưởng của ngưỡng đến hiệu suất XGBoost	42
13	Đánh giá chi tiết mô hình XGBoost tối ưu	42
14	Top 5 đặc trưng quan trọng nhất - XGBoost	42
15	Kết quả đánh giá chi tiết mô hình Logistic Regression	46
16	Kết quả đánh giá chi tiết mô hình Random Forest sau tối ưu	46
17	Kết quả đánh giá chi tiết mô hình XGBoost sau tối ưu toàn diện	47
18	So sánh toàn diện hiệu năng ba mô hình học máy	47
19	Ảnh hưởng của ngưỡng phân lớp đến hiệu năng mô hình XGBoost	48

1 CHƯƠNG I: TỔNG QUAN

1.1 Lý do chọn đề tài

Trong bối cảnh sự phát triển mạnh mẽ của công nghệ tài chính (FinTech), các hình thức thanh toán điện tử và giao dịch không dùng tiền mặt ngày càng phổ biến, góp phần nâng cao hiệu quả kinh tế và tối ưu hóa trải nghiệm người dùng. Tuy nhiên, song hành với xu hướng này là sự gia tăng các hành vi gian lận tín dụng và gian lận giao dịch tài chính, gây thiệt hại đáng kể cho các tổ chức tài chính và làm suy giảm niềm tin của khách hàng.

Gian lận tín dụng là một bài toán phức tạp, với đặc điểm nổi bật là dữ liệu mất cân bằng nghiêm trọng và hành vi gian lận ngày càng tinh vi, biến đổi theo thời gian. Các phương pháp phát hiện truyền thống dựa trên luật thường thiếu linh hoạt và khó thích ứng với các hình thức gian lận mới.

Xuất phát từ thực tiễn đó, cùng với mong muốn vận dụng kiến thức đã học trong môn Máy học, nhóm chúng em lựa chọn đề tài "Phân tích và dự đoán gian lận tài chính bằng các mô hình Machine Learning". Đề tài không chỉ mang ý nghĩa học thuật mà còn có tính ứng dụng cao, góp phần giúp sinh viên hiểu rõ hơn về cách Machine Learning được triển khai trong các bài toán thực tế của lĩnh vực tài chính.

1.2 Mục tiêu đề tài

Mục tiêu chính của đề tài là nghiên cứu và xây dựng các mô hình Machine Learning nhằm phát hiện các giao dịch gian lận tín dụng dựa trên dữ liệu giao dịch lịch sử. Cụ thể, đề tài hướng đến các mục tiêu sau:

- Nghiên cứu tổng quan về bài toán gian lận tín dụng và các thách thức đặc thù của bài toán này, đặc biệt là vấn đề dữ liệu mất cân bằng.
- Phân tích và khám phá tập dữ liệu PaySim, làm rõ các đặc trưng của dữ liệu giao dịch tài chính và sự khác biệt giữa giao dịch gian lận và giao dịch hợp lệ.
- Thực hiện các bước tiền xử lý dữ liệu cần thiết như làm sạch dữ liệu, chuẩn hóa, mã hóa đặc trưng và xử lý mất cân bằng dữ liệu.
- Xây dựng và so sánh hiệu quả của một số thuật toán Machine Learning phổ biến trong bài toán phân loại, bao gồm các mô hình tuyến tính và phi tuyến.
- Đánh giá hiệu suất của các mô hình thông qua các chỉ số phù hợp với bài toán gian lận tín dụng như Precision, Recall, F1-score và ROC AUC.
- Đề xuất mô hình có hiệu quả tốt nhất và thảo luận khả năng ứng dụng mô hình trong thực tế.

Thông qua việc đạt được các mục tiêu trên, nhóm chúng em mong muốn củng cố kiến thức lý thuyết về Machine Learning, đồng thời nâng cao kỹ năng phân tích dữ liệu và giải quyết các bài toán thực tế.

1.3 Phạm vi và giới hạn của đề tài

Trong phạm vi của đề tài, nhóm chúng em tập trung nghiên cứu và ứng dụng các thuật toán Machine Learning nhằm phát hiện gian lận tín dụng trên dữ liệu giao dịch tài chính. Nghiên

cứu được thực hiện trên tập dữ liệu PaySim và tập trung vào các bước phân tích dữ liệu, xây dựng mô hình, huấn luyện và đánh giá hiệu năng trong môi trường thực nghiệm.

Bên cạnh phạm vi nghiên cứu nêu trên, đề tài tồn tại một số giới hạn. Thứ nhất, dữ liệu sử dụng là dữ liệu mô phỏng PaySim được công bố công khai, do đó có thể chưa phản ánh đầy đủ các đặc điểm phức tạp, nhiễu và biến động của dữ liệu giao dịch trong các hệ thống ngân hàng thực tế. Thứ hai, đề tài chỉ xem xét các mô hình Machine Learning truyền thống và chưa đi sâu vào các phương pháp học sâu hoặc phát hiện bất thường nâng cao. Thứ ba, nghiên cứu chưa xét đến các yếu tố triển khai thực tế như xử lý thời gian thực, chi phí vận hành và các yêu cầu về bảo mật hệ thống.

Do những giới hạn trên, kết quả của đề tài mang ý nghĩa tham khảo và học thuật, có thể cần được điều chỉnh và mở rộng khi áp dụng vào các hệ thống tài chính thực tế khác nhau.

1.4 Phương pháp nghiên cứu

Để thực hiện đề tài một cách có hệ thống và khoa học, nhóm chúng em áp dụng các phương pháp nghiên cứu sau:

- **Phương pháp nghiên cứu tài liệu:** Thu thập và phân tích các bài báo khoa học, công trình nghiên cứu và tài liệu học thuật liên quan đến gian lận tín dụng và ứng dụng Machine Learning trong lĩnh vực tài chính.
- **Phân tích và khám phá dữ liệu:** Thực hiện phân tích khám phá dữ liệu (EDA) nhằm hiểu rõ cấu trúc dữ liệu, phân bố các đặc trưng và mức độ mất cân bằng giữa các lớp.
- **Tiền xử lý dữ liệu:** Áp dụng các kỹ thuật làm sạch dữ liệu, xử lý giá trị thiếu, chuẩn hóa và xử lý dữ liệu mất cân bằng nhằm nâng cao chất lượng dữ liệu đầu vào cho mô hình.
- **Xây dựng mô hình Machine Learning:** Triển khai và huấn luyện các mô hình phân loại để phát hiện gian lận tín dụng dựa trên dữ liệu đã được xử lý.
- **Đánh giá mô hình:** Sử dụng các chỉ số đánh giá phù hợp với bài toán gian lận tín dụng để so sánh và lựa chọn mô hình hiệu quả nhất.
- **Phân tích và thảo luận kết quả:** Phân tích kết quả thực nghiệm, chỉ ra ưu điểm, hạn chế của từng mô hình và thảo luận khả năng ứng dụng trong thực tế.

1.5 Giới thiệu về nhóm và Quy trình quản lý chất lượng

Để đảm bảo tính khách quan, khả năng tái lập và chất lượng học thuật xuyên suốt dự án, nhóm nghiên cứu đã xây dựng và vận hành một quy trình làm việc hệ thống dựa trên **Team Protocol** kết hợp với chỉ số đánh giá năng lực **H-score** (Human-Score). Cơ chế này không chỉ phân định rõ vai trò mà còn tạo ra một vòng lặp kiểm soát chất lượng chặt chẽ cho mọi đầu ra, từ phân tích dữ liệu đến huấn luyện và đánh giá mô hình.

Team Protocol: Cơ chế Lead – Verifier và Áp dụng thực tế

Mỗi nhiệm vụ được giao cho một thành viên đảm nhận vai trò **Lead** – chịu trách nhiệm chính về thực thi. Sau khi hoàn thành, sản phẩm (code, phân tích, báo cáo) được chuyển cho hai thành viên còn lại trong vai trò **Verifier** để kiểm tra độc lập dựa trên ba trụ cột:

- **Tính chính xác (Correctness):** Kiểm tra logic, cú pháp mã nguồn và tính đúng đắn của các phép toán.

- **Tính tổng quát (Generalization):** Rà soát nguy cơ rò rỉ dữ liệu (data leakage) và đánh giá khả năng khái quát hóa của mô hình.
- **Tính bền vững (Robustness):** Kiểm tra độ ổn định thông qua các thử nghiệm ngẫu nhiên và điều kiện biên.

Quy trình này được áp dụng nhất quán cho tất cả các giai đoạn then chốt của dự án: **tiền xử lý dữ liệu và xây dựng đặc trưng, huấn luyện mô hình Logistic Regression, Random Forest, XGBoost, và đánh giá, so sánh hiệu năng.**

H-score: Đánh giá năng lực và Phân công công việc

H-score là một chỉ số tổng hợp đánh giá năng lực thành viên dựa trên bốn khía cạnh chuyên môn chính: **C**orrectness (Độ chính xác), **G**eneralization (Khả năng tổng quát hóa), **R**obustness (Độ bền vững), và **M**communication (Khả năng truyền đạt). Chỉ số này được sử dụng như một công cụ hỗ trợ ra quyết định để phân công các nhiệm vụ có độ phức tạp và yêu cầu kỹ thuật cao (như tối ưu siêu tham số với Optuna, xử lý mất cân bằng dữ liệu) cho những thành viên có năng lực phù hợp nhất, nhằm tối ưu hóa nguồn lực và đảm bảo chất lượng đầu ra.

Phân công nhiệm vụ cụ thể và Đánh giá năng lực thành viên

Dựa trên nguyên tắc của Team Protocol và đánh giá H-score, nhiệm vụ được phân công cụ thể như sau:

Thành viên 1: Tạ Chí Bình – Chủ trì kỹ thuật (Technical Lead)

- **Vai trò chính (Lead):** Đảm nhiệm phần xây dựng nền tảng kỹ thuật. Cụ thể, Bình chịu trách nhiệm chính trong việc phân tích cấu trúc dữ liệu PaySim, thiết kế và thực thi toàn bộ **quy trình tiền xử lý dữ liệu, trực tiếp xây dựng, huấn luyện và tối ưu cả ba mô hình máy học** (Logistic Regression, Random Forest, XGBoost), cũng như triển khai các kỹ thuật nâng cao như sử dụng **Optuna** để tinh chỉnh siêu tham số và **SMOTE/scale_pos_weight** để xử lý vấn đề mất cân bằng lớp.
- **Vai trò phụ (Verifier):** Tham gia kiểm tra tính tổng quát và độ bền vững cho các phân tích đánh giá mô hình do thành viên khác thực hiện.
- **Đánh giá H-score (trên thang điểm 10): C:9, G:8, R:9, M:8.** Điểm số phản ánh thể mạnh vượt trội về độ chính xác kỹ thuật (C) và khả năng xây dựng hệ thống ổn định (R), với vai trò kỹ thuật nòng cốt.

Thành viên 2: Phan Tấn Phúc – Phản biện học thuật và Kiểm định phương pháp

- **Vai trò chính (Verifier):** Đảm nhiệm vai trò kiểm soát chất lượng then chốt. Phúc là người chịu trách nhiệm chính trong việc kiểm tra **tính chính xác** của quy trình tiền xử lý, với nhiệm vụ trọng tâm là phát hiện và đề xuất loại bỏ các biến có nguy cơ **rò rỉ dữ liệu (data leakage)**. Đồng thời, kiểm tra và note chú thích code rõ ràng.
- **Vai trò phụ (Lead):** Chủ trì việc **diễn giải kết quả** kỹ thuật, đảm bảo tính nhất quán và chặt chẽ về mặt học thuật trong mọi báo cáo.
- **Đánh giá H-score (trên thang điểm 10): C:8, G:9, R:8, M:9.** Điểm số này cho thấy tư duy tổng quát hóa xuất sắc (G) và khả năng truyền đạt rõ ràng (M), là yếu tố thiết yếu cho công tác phản biện và diễn giải.

Thành viên 3: Phạm Nguyễn Bảo Vi – Chủ trì Đánh giá và Tổng hợp kết quả

- **Vai trò chính (Lead):** Đảm nhiệm giai đoạn tổng kết và đánh giá. Vì trách nhiệm thiết kế khung **đánh giá và so sánh toàn diện** giữa các mô hình (dựa trên ROC-AUC, F1-score, Confusion Matrix), thực hiện phân tích sâu về **sự đánh đổi giữa Precision và Recall (Precision-Recall trade-off)** cũng như công việc **tối ưu hóa ngưỡng phân loại**. Cuối cùng, bạn chủ trì việc tổng hợp toàn bộ kết quả thành báo cáo và bài trình bày hoàn chỉnh.
- **Vai trò phụ (Verifier):** Kiểm tra tính chính xác của các biểu đồ, bảng số liệu cuối cùng trước khi xuất bản.
- **Đánh giá H-score (trên thang điểm 10): C:8, G:8, R:9, M:9.** Điểm số này nhấn mạnh khả năng đánh giá hệ thống một cách bền vững, toàn diện (R) và kỹ năng tổng hợp, truyền đạt thông tin xuất sắc (M).

Tỷ lệ đóng góp: Dựa trên khối lượng công việc chuyên môn trực tiếp và vai trò chủ trì trong các giai đoạn then chốt, tỷ lệ đóng góp được đánh giá như sau: Thành viên Tạ Chí Bình: 40%, Thành viên Phan Tấn Phúc: 30%, Thành viên Phạm Nguyễn Bảo Vi: 30%. Cần nhấn mạnh rằng, trên tinh thần đồng đội của Team Protocol, sự đóng góp về mặt ý tưởng, phản biện và kiểm soát chất lượng của cả ba thành viên đều có giá trị ngang hàng và là yếu tố không thể thiếu cho thành công chung của dự án.

Tổng kết

Việc áp dụng đồng bộ Team Protocol và H-score đã giúp nhóm đạt được những kết quả quan trọng: (1) **Tính chính xác cao** trong từng mô hình, thể hiện qua việc loại bỏ hoàn toàn các lỗi data leakage nghiêm trọng; (2) **Khả năng tổng quát hóa tốt** của các mô hình cuối cùng, đặc biệt là XGBoost; và (3) **Sự phân công tối ưu**, khi thành viên có điểm H-score cao về Correctness (C) và Robustness (R) đảm nhiệm phần xây dựng mô hình phức tạp, trong khi thành viên có điểm Generalization (G) và Communication (M) cao đảm nhiệm phản biện và tổng hợp. Điều này khẳng định tính hiệu quả của quy trình quản lý chất lượng trong việc nâng cao thành công học thuật của dự án.

2 CHƯƠNG 2: DỮ LIỆU VÀ PHÂN TÍCH KHÁM PHÁ (EDA)

2.1 Giới thiệu tập dữ liệu PAYSIM

Trong đề tài này, nhóm chúng em sử dụng tập dữ liệu PaySim, được công bố chính thức trên nền tảng Kaggle: <https://www.kaggle.com/datasets/ealaxi/paysim1?resource=download>.

PaySim là một tập dữ liệu mô phỏng các giao dịch trong hệ thống thanh toán di động, được xây dựng dựa trên dữ liệu thực tế của một nhà cung cấp dịch vụ mobile money, với mục tiêu tái hiện các hành vi giao dịch hợp lệ và gian lận trong môi trường tài chính số.

Tập dữ liệu gốc của PaySim bao gồm hơn 6 triệu giao dịch, phản ánh quy mô lớn và tính thực tế cao của hệ thống thanh toán di động. Mỗi bản ghi trong tập dữ liệu đại diện cho một giao dịch tài chính và được mô tả bởi 11 thuộc tính, bao gồm:

- step: thời gian xảy ra giao dịch, được mô phỏng theo đơn vị giờ;
- type: loại hình giao dịch tài chính (ví dụ: PAYMENT, TRANSFER, CASH_OUT, CASH_IN, DEBIT);

- amount: số tiền của giao dịch;
- nameOrig: mã định danh của tài khoản người gửi;
- oldbalanceOrg: số dư của người gửi trước giao dịch;
- newbalanceOrig: số dư của người gửi sau giao dịch;
- nameDest: mã định danh của tài khoản người nhận;
- oldbalanceDest: số dư của người nhận trước giao dịch;
- newbalanceDest: số dư của người nhận sau giao dịch;
- isFraud: nhãn mục tiêu, trong đó giá trị 1 biểu thị giao dịch gian lận và 0 biểu thị giao dịch hợp lệ;
- isFlaggedFraud: cờ cảnh báo gian lận do hệ thống quy tắc đặt ra đối với các giao dịch có giá trị bất thường lớn.

Do quy mô rất lớn của tập dữ liệu gốc (hơn 6 triệu dòng), việc huấn luyện và đánh giá nhiều mô hình Machine Learning khác nhau đòi hỏi tài nguyên tính toán lớn và thời gian xử lý đáng kể. Trong phạm vi một bài tiểu luận học phần, nhằm đảm bảo tính khả thi trong quá trình thực nghiệm và vẫn giữ được đặc trưng của bài toán gian lận tín dụng, nhóm chúng em tiến hành trích xuất một tập con dữ liệu từ tập dữ liệu gốc.

Cụ thể, tập dữ liệu được sử dụng trong đề tài có kích thước 325,934 dòng và 11 cột. Việc lựa chọn tập con này được thực hiện nhằm:

- Giảm chi phí tính toán và thời gian huấn luyện mô hình;
- Tạo điều kiện thuận lợi cho việc thử nghiệm, so sánh nhiều thuật toán Machine Learning;
- Vẫn đảm bảo dữ liệu đủ lớn để phản ánh đặc điểm mất cân bằng và các hành vi gian lận đặc trưng của hệ thống PaySim.

Tập dữ liệu sau khi trích xuất vẫn giữ nguyên cấu trúc, ý nghĩa các thuộc tính và phân bố nhãn gian lận của tập dữ liệu gốc, do đó phù hợp cho mục tiêu nghiên cứu và đánh giá các mô hình phát hiện gian lận tín dụng trong khuôn khổ đề tài.

2.2 Ý nghĩa và phạm vi giá trị của các biến

Trong tập dữ liệu PaySim, các thuộc tính được thiết kế nhằm phản ánh đầy đủ bối cảnh và trạng thái của mỗi giao dịch tài chính. Biến step biểu diễn thời điểm xảy ra giao dịch theo đơn vị giờ kể từ khi hệ thống bắt đầu mô phỏng, cho phép phân tích hành vi gian lận theo yếu tố thời gian. Biến type mô tả loại hình giao dịch tài chính, đóng vai trò là biến ngữ cảnh quan trọng phản ánh bản chất nghiệp vụ của giao dịch, đặc biệt đối với các giao dịch chuyển tiền và rút tiền – những bối cảnh có nguy cơ gian lận cao.

Biến amount là biến định lượng liên tục, biểu diễn số tiền của giao dịch và có phân phối lệch phải, với phạm vi giá trị trải rộng từ các giao dịch nhỏ đến các giao dịch có giá trị rất lớn. Nhóm các biến số dư, bao gồm oldbalanceOrg, newbalanceOrig, oldbalanceDest và newbalanceDest, mô tả trạng thái tài khoản của người gửi và người nhận trước và sau giao dịch, qua đó phản ánh tính nhất quán của dòng tiền trong mỗi giao dịch. Các biến này có giá trị không âm và chịu ràng buộc kế toán giữa trạng thái trước và sau giao dịch, là cơ sở quan trọng để phát hiện các bất thường liên quan đến gian lận.


Hai biến `nameOrig` và `nameDest` là các biến định danh tài khoản, cho phép phân tích mức độ lặp lại và cấu trúc hành vi của các tài khoản tham gia giao dịch gian lận, nhưng không được sử dụng trực tiếp trong huấn luyện mô hình nhằm tránh làm giảm khả năng tổng quát hóa. Biến `isFraud` là nhãn mục tiêu của bài toán, với giá trị (1) biểu thị giao dịch gian lận và (0) biểu thị giao dịch hợp lệ, phản ánh đặc điểm mất cân bằng nghiêm trọng của dữ liệu. Bên cạnh đó, biến `isFlaggedFraud` đại diện cho cơ chế phát hiện gian lận dựa trên luật của hệ thống, thường chỉ kích hoạt đối với các giao dịch có giá trị bất thường lớn và được sử dụng như một tham chiếu so sánh với các phương pháp học máy trong nghiên cứu này.

2.3 Phân tích và khám phá dữ liệu (Exploratory Data Analysis)

Việc thực hiện EDA là bước quan trọng, giúp định hướng các quyết định về tiền xử lý dữ liệu, lựa chọn đặc trưng và xây dựng mô hình Machine Learning ở các chương tiếp theo.

2.3.1 Kiểm tra chất lượng dữ liệu và giá trị thiếu và bản ghi trùng lặp

Trước hết, nhóm chúng em kiểm tra sự tồn tại của giá trị thiếu (missing values) trong tập dữ liệu. Kết quả kiểm tra và trực quan hóa cho thấy tập dữ liệu PaySim không chứa giá trị thiếu theo nghĩa kỹ thuật ở các thuộc tính. Hình 2.1 minh họa mức độ đầy đủ dữ liệu theo từng cột, cho thấy tất cả các thuộc tính đều có thông tin đầy đủ.



Hình 2.1: Mức độ đầy đủ dữ liệu theo từng thuộc tính (missingness overview).

Bên cạnh đó, nhóm chúng em cũng tiến hành kiểm tra các bản ghi trùng lặp (duplicate records) nhằm đảm bảo mỗi giao dịch trong tập dữ liệu được xem là một quan sát độc lập. Kết quả cho thấy dữ liệu không tồn tại (hoặc chỉ tồn tại rất ít) các bản ghi trùng lặp, và các bản ghi này không ảnh hưởng đáng kể đến cấu trúc tổng thể của dữ liệu. Việc xác nhận điều này giúp tránh nguy cơ mô hình học lệch do các mẫu lặp lại và đảm bảo tính khách quan trong quá trình huấn luyện và đánh giá mô hình.

2.3.2 Phân bố nhãn gian lận và hàm ý đối với đánh giá mô hình

Một đặc trưng cốt lõi của bài toán gian lận là tính hiếm gặp của lớp gian lận. Điều này không chỉ gây khó khăn cho mô hình trong việc "nhìn thấy đủ ví dụ gian lận để học", mà còn khiến các thước đo đánh giá dễ bị hiểu sai nếu chọn không phù hợp.



Hình 2.2: Phân bố nhãn gian lận (isFraud).


Hình 2.2 thể hiện phân bố của nhãn isFraud, cho thấy lớp gian lận là lớp thiểu số rõ rệt. Từ góc độ học máy, sự mất cân bằng này có các hệ quả quan trọng:

- Accuracy có thể gây đánh giá ảo: nếu mô hình dự đoán tất cả giao dịch là "không gian lận", accuracy vẫn có thể rất cao do lớp đa số chiếm tỷ trọng áp đảo, nhưng mô hình hoàn toàn thất bại trong mục tiêu chính là phát hiện gian lận.
- Sai lầm loại II (false negative) đặc biệt nguy hiểm: bỏ sót gian lận thường dẫn đến thiệt hại tài chính trực tiếp. Vì vậy, trong bài toán này cần ưu tiên kiểm soát false negative, tương đương ưu tiên Recall cho lớp gian lận.
- Đánh đổi Precision – Recall là tất yếu: nâng Recall thường làm tăng false positive, do đó cần đánh giá cân bằng qua F1-score hoặc dùng đường ROC/PR để lựa chọn ngưỡng quyết định phù hợp.

2.3.3 Phân tích loại hình gian lận và mối liên hệ với gian lận

Trong các hệ thống thanh toán điện tử, mỗi loại hình giao dịch đại diện cho một cơ chế vận hành và dịch chuyển dòng tiền khác nhau, từ đó kéo theo các mức độ rủi ro gian lận khác nhau. Do đó, việc phân tích biến type giúp xác định những bối cảnh giao dịch mà trong đó hành vi gian lận có khả năng xảy ra cao hơn, thay vì trực tiếp kết luận giao dịch có gian lận hay không.

Nhằm đánh giá vai trò của đặc trưng type, nhóm chúng em tiến hành so sánh phân bố các giao dịch gian lận và không gian lận theo từng loại hình giao dịch. Kết quả được trình bày trong Hình 2.3, thể hiện số lượng giao dịch theo từng loại hình và được phân tách theo nhãn isFraud.



Hình 2.3: Phân bố giao dịch theo loại hình giao dịch (type) và nhãn gian lận (isFraud).

Quan sát từ Hình 2.3 cho thấy rằng, trong tập dữ liệu PaySim được sử dụng, các giao dịch được gắn nhãn gian lận chỉ xuất hiện trong hai loại hình giao dịch là TRANSFER và CASH_OUT, trong khi các loại giao dịch còn lại (CASH_IN, PAYMENT và DEBIT) không ghi nhận gian lận. Kết quả này cho thấy hành vi gian lận trong dữ liệu bị giới hạn trong một số bối cảnh giao dịch nhất định, thay vì phân bố ngẫu nhiên trên toàn bộ hệ thống.

Phân bố gian lận theo loại giao dịch

```
type
CASH_OUT    50.11567
TRANSFER    49.88433
Name: proportion, dtype: float64
```


Kết quả trên cho thấy gian lận chỉ xuất hiện ở hai loại hình TRANSFER và CASH_OUT, đồng thời tỷ trọng giữa hai loại hình này tương đối cân bằng. Về mặt nghiệp vụ, đây là cấu trúc hợp lý: TRANSFER đóng vai trò dịch chuyển dòng tiền (tạo điều kiện tách nguồn), còn CASH_OUT đóng vai trò rút tiền ra khỏi hệ thống (hiện thực hóa lợi ích). Do đó, phân bố này củng cố nhận định rằng gian lận trong PaySim không đơn thuần là "giao dịch bất thường", mà là một cơ chế có đích rõ ràng: chuyển-rút để chiếm đoạt.

Từ góc độ học máy, kết quả này đặt ra hai hàm ý. Thứ nhất, type là một đặc trưng quan trọng giúp mô hình định vị bối cảnh rủi ro; tuy nhiên, vì type có sức phân tách mạnh, mô hình có thể phụ thuộc quá mức vào biến này nếu không kết hợp thêm các tín hiệu định lượng (amount, số dư). Thứ hai, việc gian lận tập trung vào hai loại hình này gợi ý rằng các phân tích và đánh giá mô hình cần quan tâm đến hiệu năng trong các giao dịch TRANSFER/CASH_OUT, tránh đánh giá "ảo" do mô hình dự đoán luôn là không gian lận trên các loại hình khác.

2.3.4 Phân tích giá trị giao dịch và vai trò trong nhận diện gian lận


Trong các bài toán phát hiện gian lận tài chính, giá trị giao dịch (amount) là một trong những đặc trưng định lượng quan trọng nhất, bởi nó phản ánh trực tiếp quy mô dòng tiền liên quan đến mỗi giao dịch. Trên thực tế, các giao dịch gian lận thường không phân bố ngẫu nhiên theo giá trị tiền tệ, mà có xu hướng tập trung vào những khoảng giá trị nhất định nhằm tối đa hóa lợi ích hoặc tránh các cơ chế giám sát tự động.

Nhằm làm rõ mối quan hệ giữa amount và hành vi gian lận, nhóm chúng em tiến hành phân tích phân bố giá trị giao dịch và so sánh giữa các giao dịch gian lận và không gian lận. Kết quả phân tích được trình bày trong Hình 2.4 và Hình 2.5, lần lượt thể hiện phân bố amount dưới dạng boxplot và histogram, đều được trình bày trên thang log để phản ánh chính xác đặc điểm phân phối lệch của dữ liệu.



Hình 2.4: Phân bố giá trị giao dịch (amount) theo nhãn gian lận, biểu diễn bằng boxplot trên thang log.

Quan sát từ Hình 2.4 cho thấy phân phối amount có độ lệch phải mạnh, với phần lớn các giao dịch có giá trị nhỏ và một số ít giao dịch có giá trị rất lớn. Sự tồn tại của các giá trị ngoại lai là đặc trưng phổ biến trong dữ liệu giao dịch tài chính và cũng được ghi nhận rõ trong tập dữ liệu PaySim. Khi so sánh giữa hai lớp, các giao dịch gian lận có xu hướng xuất hiện nhiều hơn ở các mức giá trị giao dịch cao, đồng thời thể hiện mức độ phân tán lớn hơn so với các giao dịch hợp lệ.



Hình 2.5: Phân bố mật độ giá trị giao dịch (amount) theo nhãn gian lận, biểu diễn bằng histogram trên thang log.

Hình 2.5 cung cấp góc nhìn bổ sung thông qua phân bố mật độ của amount theo từng nhãn. Việc sử dụng histogram theo mật độ trên thang log giúp làm rõ sự khác biệt về hình dạng phân phối giữa hai lớp trong bối cảnh dữ liệu mất cân bằng. Kết quả cho thấy mặc dù phần lớn giao dịch (cả gian lận và không gian lận) tập trung ở vùng giá trị thấp, nhưng xác suất tương đối của gian lận tăng lên ở các khoảng giá trị giao dịch lớn hơn.


2.3.5 Phân tích bất thường số dư và mối liên hệ với gian lận

Trong các hệ thống giao dịch tài chính, một giao dịch hợp lệ thường tuân theo các ràng buộc kế toán cơ bản, trong đó sự thay đổi số dư trước và sau giao dịch phải phù hợp với giá trị giao dịch và loại hình giao dịch tương ứng. Do đó, các bất thường trong cập nhật số dư được xem là một trong những chỉ báo quan trọng để nhận diện hành vi gian lận.

Trong tập dữ liệu PaySim, nhóm chúng em phân tích bất thường số dư thông qua mối quan hệ giữa số dư trước giao dịch, số dư sau giao dịch và giá trị giao dịch ở cả phía người gửi và người nhận. Hai đại lượng sai số được xem xét phản ánh mức độ "không khớp" của biến động số dư so với dòng tiền giao dịch, qua đó cho phép đánh giá tính nhất quán của giao dịch. Kết quả phân tích được minh họa trong Hình 2.6 và Hình 2.7.



Hình 2.6: Phân bố sai số cân bằng số dư của người gửi theo nhãn gian lận.



Hình 2.7: Phân bố sai số cân bằng số dư của người nhận theo nhãn gian lận.

Quan sát từ Hình 2.6 cho thấy đối với các giao dịch hợp lệ, sai số cân bằng số dư của người gửi thường tập trung quanh một vùng giá trị hẹp, phản ánh sự tuân thủ các ràng buộc kế toán. Ngược lại, trong các giao dịch gian lận, phân bố sai số trở nên phân tán hơn và xuất hiện nhiều giá trị lệch lớn, cho thấy tồn tại các bất thường rõ rệt trong việc cập nhật số dư của tài khoản nguồn.

Tương tự, Hình 2.7 cho thấy các giao dịch gian lận cũng xuất hiện sai lệch đáng kể trong cân bằng số dư của người nhận. Việc bất thường xảy ra đồng thời ở cả phía người gửi và người nhận cho thấy gian lận trong PaySim không chỉ liên quan đến việc rút tiền từ tài khoản nguồn, mà còn gắn với các bất thường trong dòng tiền và trạng thái tài khoản đích.

2.3.6 Phân tích mối liên hệ giữa chuỗi giao dịch chuyển tiền và rút tiền trong các giao dịch gian lận.

Transfer linked to Cash-out: 0.006549217368524461 %

Phân tích chuỗi giao dịch cho thấy một tỷ lệ nhỏ các giao dịch TRANSFER có liên kết trực tiếp với các giao dịch CASH_OUT tiếp theo. Điều này cho thấy gian lận không chỉ thể hiện ở từng giao dịch riêng lẻ, mà còn tồn tại dưới dạng các chuỗi hành vi có cấu trúc.

Phát hiện này nhấn mạnh tầm quan trọng của việc xem xét ngữ cảnh giao dịch và mối liên hệ giữa các giao dịch, thay vì chỉ phân tích từng giao dịch độc lập.

2.3.7 Phân tích tài khoản nguồn và đích trong các giao dịch gian lận.

Trong các bài toán phát hiện gian lận, phân tích định danh tài khoản có hai mục tiêu học thuật quan trọng: (i) kiểm tra liệu gian lận có tập trung vào một số ít thực thể (tài khoản "điểm nóng") hay không; và (ii) đánh giá nguy cơ mô hình học theo dấu vết định danh (identity memorization) thay vì học theo hành vi. Với PaySim, hai trường định danh nameOrig (người gửi) và nameDest (người nhận) cho phép kiểm tra trực tiếp giả thuyết này trong tập các giao dịch gian lận.

nameOrig	
C610113599	1
C161612692	1
C2079730259	1

```

C927253405      1
C382898342      1
C431054678      1
C533706573      1
C2086071347     1
C920552627      1
C911097587      1
Name: count, dtype: int64

```

```

nameDest
C643624257      2
C1655359478     2
C2129197098     2
C1399829166     2
C1780714769     2
C644163395      2
C686334805      2
C1650668671     2
C1460854172     2
C1193568854     2
Name: count, dtype: int64

```

Kết quả thống kê cho thấy mức độ lặp lại của các định danh trong tập gian lận không cao, tức là không xuất hiện hiện tượng "một vài tài khoản chi phối phần lớn gian lận". Về mặt hành vi, điều này gợi ý rằng gian lận trong dữ liệu không được mô phỏng như một nhóm nhỏ đối tượng cố định, mà phản ánh một cơ chế gian lận có thể xảy ra trên nhiều tài khoản khác nhau. Về mặt mô hình hóa, phát hiện này có ý nghĩa tích cực: mô hình khó có thể đạt hiệu năng cao chỉ bằng cách "ghi nhớ" một số định danh thường xuyên gian lận; thay vào đó, mô hình buộc phải khai thác các đặc trưng phản ánh ngữ cảnh và dòng tiền (type, amount, số dư và các bất thường liên quan).

2.3.8 Phân tích trạng thái không đủ số dư của người gửi trong giao dịch gian lận

```

sender_insufficient_balance
0      99.646901
1       0.353099
Name: proportion, dtype: float64


```

Kết quả cho thấy tỷ lệ giao dịch gian lận rơi vào trạng thái `oldbalanceOrg < amount` là rất nhỏ. Điều này hàm ý rằng gian lận trong PaySim thường diễn ra trong các điều kiện bề ngoài có vẻ hợp lệ về mặt số dư, khiến việc nhận diện không thể dựa vào một điều kiện đơn lẻ. Nói cách khác, gian lận thể hiện qua tổ hợp tín hiệu (type, amount, bất thường số dư, hành vi chuỗi), thay vì một "vi phạm hiển nhiên" về khả năng chi trả.

2.3.9 Phân tích yếu tố thời gian theo ngày và giờ trong giao dịch.

Từ biến thời gian `step`, nhóm chúng em xây dựng các đặc trưng giờ trong ngày (hour) và ngày giao dịch (day) để phân tích sự phân bố của các giao dịch gian lận theo thời gian. Kết quả cho thấy gian lận không phân bố đồng đều, mà có sự dao động theo cả giờ và ngày giao dịch. Mặc dù EDA không nhằm khẳng định mối quan hệ nhân quả, các mô hình phân bố này cho thấy dữ liệu có dấu hiệu không hoàn toàn độc lập và phân phối không đổi theo thời gian.

Phát hiện này có ý nghĩa quan trọng đối với quá trình xây dựng mô hình. Cụ thể, nếu dữ liệu được chia ngẫu nhiên giữa tập huấn luyện và kiểm tra mà không xét đến yếu tố thời gian, mô hình có thể gián tiếp khai thác thông tin tương lai, dẫn đến đánh giá lạc quan sai lệch về hiệu năng.




Hình 2.8: Phân bố giao dịch gian lận theo ngày và giờ.

2.3.10 Phân tích ma trận tương quan giữa các đặc trưng

Ma trận tương quan cho thấy các biến liên quan đến số dư trước và sau giao dịch của cùng một phía (người gửi hoặc người nhận) có mức tương quan cao với nhau, phản ánh tính nhất quán trong dòng tiền của các giao dịch thông thường.

Ngược lại, biến mục tiêu 'isFraud' có mức tương quan tuyến tính thấp với hầu hết các biến đầu vào, cho thấy gian lận không thể được phát hiện hiệu quả chỉ dựa trên các mối quan hệ tuyến tính đơn giản.

Điều này cho thấy cần kết hợp các đặc trưng phi tuyến, các đặc trưng được xây dựng thủ công (feature engineering) và các luật nghiệp vụ để nâng cao hiệu quả phát hiện gian lận, thay vì chỉ dựa vào phân tích tương quan tuyến tính.



Hình 2.9: Ma trận tương quan giữa các đặc trưng

3 CHƯƠNG 3: CƠ SỞ LÝ THUYẾT VÀ LỰA CHỌN MÔ HÌNH

3.1 Đặc thù bài toán gian lận tín dụng và yêu cầu đối với mô hình

Bài toán phát hiện gian lận tín dụng là một bài toán phân loại nhị phân với nhiều đặc thù phức tạp. Trước hết, dữ liệu gian lận thường có tính **mất cân bằng nghiêm trọng**, trong đó số lượng giao dịch gian lận chỉ chiếm một tỷ lệ rất nhỏ so với tổng số giao dịch hợp lệ. Điều này khiến các mô hình học máy dễ thiên lệch về lớp đa số nếu không được thiết kế và đánh giá phù hợp.

Bên cạnh đó, gian lận tài chính thường có **hành vi biến đổi theo thời gian** và các thủ đoạn ngày càng tinh vi, đòi hỏi mô hình không chỉ có độ chính xác cao mà còn cần **khả năng thích ứng và phát hiện các mẫu bất thường mới**. Hơn nữa, trong bối cảnh tài chính – ngân hàng, **chi phí của các loại sai lầm là không đối xứng**: một false negative (bỏ sót gian lận) có thể gây thiệt hại trực tiếp về tài chính và uy tín, trong khi false positive (cảnh báo sai) có thể làm giảm trải nghiệm khách hàng và tốn kém nguồn lực kiểm tra.

Xuất phát từ các đặc thù trên, việc lựa chọn mô hình trong đề tài được thực hiện dựa trên các tiêu chí chính:

1. **Khả năng xử lý dữ liệu mất cân bằng** và cho phép điều chỉnh trọng số lớp hoặc ngưỡng dự đoán.
2. **Khả năng mô hình hóa các quan hệ phi tuyến và tương tác phức tạp** giữa các đặc trưng.

3. **Hiệu năng dự đoán cao**, đặc biệt trên các chỉ số quan trọng như Recall và F1-score.
4. **Mức độ diễn giải nhất định** để phục vụ phân tích nguyên nhân và đưa ra cảnh báo có ý nghĩa nghiệp vụ.
5. **Cân nhắc góc nhìn xác suất**: khả năng cung cấp xác suất dự đoán đáng tin cậy (well-calibrated) để hỗ trợ ra quyết định dựa trên rủi ro.

3.2 Các chỉ số đánh giá trong bài toán phân loại mất cân bằng

Trong bối cảnh dữ liệu gian lận cực kỳ mất cân bằng, việc lựa chọn chỉ số đánh giá phù hợp là yếu tố then chốt để đánh giá đúng hiệu năng mô hình và định hướng tối ưu hóa.

Giới hạn của Accuracy trong bài toán mất cân bằng

Accuracy (độ chính xác chung) là tỷ lệ dự đoán đúng trên tổng số mẫu:

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}$$

Tuy phổ biến, nó trở nên vô nghĩa trong bài toán có tỷ lệ lớp thiểu số rất thấp. Một mô hình "ngây thơ" luôn dự đoán "KHÔNG gian lận" có thể đạt accuracy lên tới 99.9% trên tập dữ liệu chỉ có 0.1% gian lận, nhưng thực tế **hoàn toàn thất bại** trong nhiệm vụ phát hiện gian lận [?]. Do đó, accuracy không được sử dụng làm thước đo chính trong đề tài này.

Precision, Recall và ý nghĩa trong phát hiện gian lận

- **Precision (Độ chính xác dự đoán)**: $\text{Precision} = \frac{TP}{TP+FP}$. Nó đo lường **trong số các giao dịch bị nghi ngờ là gian lận, có bao nhiêu phần trăm thực sự là gian lận**. Precision cao đồng nghĩa với việc cảnh báo có độ tin cậy cao, giảm chi phí kiểm tra cho các cảnh báo sai.

Trong bối cảnh phát hiện gian lận, Precision cao giúp tiết kiệm nguồn lực và tránh làm phiền khách hàng hợp lệ.

- **Recall (Độ nhạy/Độ phủ)**: $\text{Recall} = \frac{TP}{TP+FN}$. Nó đo lường **trong tổng số các giao dịch gian lận thực tế, mô hình phát hiện được bao nhiêu phần trăm**. Recall cao đồng nghĩa với việc bỏ sót ít gian lận, giảm thiểu thiệt hại.

Trong phát hiện gian lận, Recall thường được ưu tiên vì chi phí của một giao dịch gian lận bị bỏ sót thường rất lớn.

Giữa Precision và Recall luôn tồn tại **sự đánh đổi (trade-off)**: việc cố gắng bắt được nhiều gian lận hơn (tăng Recall) thường dẫn đến nhiều cảnh báo sai hơn (giảm Precision).

F1-score và F-score: Cân bằng giữa Precision và Recall

Để kết hợp hai chỉ số này thành một thước đo duy nhất, người ta sử dụng **F-score**. Phiên bản phổ biến nhất là **F1-score** – trung bình điều hòa của Precision và Recall [?]:

$$F_1 = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}} = \frac{2TP}{2TP + FP + FN}$$

F1-score chỉ cao khi cả Precision và Recall đều cao, thể hiện sự **cân bằng** giữa hai mục tiêu.

Tuy nhiên, tùy theo mục tiêu nghiệp vụ, ta có thể muốn nhấn mạnh Recall hoặc Precision hơn. **F-score** là dạng tổng quát, cho phép điều chỉnh mức độ quan trọng tương đối thông qua tham số [?]:

$$F_\beta = (1 + \beta^2) \cdot \frac{\text{Precision} \cdot \text{Recall}}{(\beta^2 \cdot \text{Precision}) + \text{Recall}}$$

- $= 1$: Cho ta F1-score (cân bằng).
- > 1 : Recall được coi trọng hơn Precision. Ví dụ, F2-score ($=2$) "đặt nặng" Recall gấp đôi so với Precision [?].
- < 1 : Precision được coi trọng hơn Recall. Ví dụ, F0.5-score ($=0.5$) "đặt nặng" Precision gấp đôi so với Recall.

Lựa chọn chỉ số phù hợp với mục tiêu phát hiện gian lận

Đối với bài toán phát hiện gian lận tín dụng trong đề tài này, **Recall là chỉ số ưu tiên hàng đầu** nhằm giảm thiểu thiệt hại do gian lận bị bỏ sót. Tuy nhiên, Precision cũng cần được duy trì ở mức hợp lý để hệ thống khả thi về mặt vận hành. Do đó, **F1-score và F2-score** là những chỉ số trung tâm để đánh giá và so sánh mô hình, bên cạnh việc xem xét riêng lẻ Precision và Recall.

ROC-AUC và PR-AUC: Đánh giá toàn diện hiệu năng mô hình

- **ROC Curve (Receiver Operating Characteristic) và AUC (Area Under Curve)**: Đường cong ROC thể hiện mối quan hệ giữa TPR (True Positive Rate, chính là Recall) và FPR (False Positive Rate) tại mọi ngưỡng phân loại có thể. **ROC-AUC** đo diện tích dưới đường cong này, phản ánh **khả năng phân biệt tổng quát** của mô hình giữa hai lớp. AUC càng gần 1, mô hình càng tốt.
- **PR Curve (Precision-Recall) và PR-AUC**: Đường cong PR thể hiện mối quan hệ giữa Precision và Recall tại mọi ngưỡng. **PR-AUC** đặc biệt quan trọng và nhạy cảm trong bối cảnh **dữ liệu mất cân bằng nghiêm trọng** [?]. Một mô hình có ROC-AUC cao nhưng PR-AUC thấp cho thấy nó gặp khó khăn trong việc duy trì Precision khi cố gắng đạt Recall cao – đây chính là thách thức của bài toán gian lận.

Kết luận cho đánh giá mô hình: Đề tài sẽ sử dụng bộ chỉ số đa chiều gồm **Recall, Precision, F1-score, ROC-AUC và PR-AUC** để đánh giá toàn diện, trong đó **F1-score và PR-AUC** là hai chỉ số chính để so sánh và lựa chọn mô hình cuối cùng.

3.3 Lựa chọn các mô hình nghiên cứu

Dựa trên các tiêu chí nêu trong Mục 3.1 và khung đánh giá từ Mục 3.2, đề tài lựa chọn ba mô hình Machine Learning tiêu biểu, đại diện cho các triết lý mô hình hóa khác nhau [?]:

1. **Logistic Regression**: Được chọn làm **mô hình nền (baseline)** nhờ cấu trúc đơn giản, khả năng diễn giải tuyệt vời, hiệu quả trong ước lượng xác suất và tính ổn định. Nó đóng vai trò chuẩn so sánh cho các mô hình phức tạp hơn.
2. **Random Forest**: Được chọn do khả năng học các quan hệ **phi tuyến và tương tác đặc trưng** một cách tự động, độ ổn định cao nhờ cơ chế ensemble (bagging), và ít nhạy cảm với nhiễu. Đây là "công cụ đa năng" phù hợp với dữ liệu phức tạp như giao dịch tài chính.
3. **XGBoost**: Được chọn là đại diện cho các **mô hình hiệu năng cao (state-of-the-art)**, đã được chứng minh vượt trội trong nhiều bài toán gian lận nhờ cơ chế boosting mạnh mẽ và regularization linh hoạt. Nó được kỳ vọng sẽ khai thác tốt nhất các mẫu gian lận tinh vi trong dữ liệu.

3.4 HỒI QUY LOGISTIC (LOGISTIC REGRESSION)

Giới thiệu thuật toán

- **Nguồn gốc:** Mô hình Hồi quy Logistic được phát triển bởi nhà thống kê người Mỹ **David Cox** vào năm 1958, dựa trên nền tảng lý thuyết về hàm logit và mô hình hồi quy tuyến tính.
- **Bài toán áp dụng:** Thuật toán này chủ yếu được sử dụng cho bài toán **phân loại nhị phân (binary classification)**. Trong lĩnh vực tài chính và phát hiện gian lận, Logistic Regression thường được áp dụng để dự đoán xác suất một giao dịch là gian lận (1) hay hợp lệ (0) dựa trên các đặc trưng đầu vào như số tiền, loại giao dịch, thời gian thực hiện, v.v. Ưu điểm của mô hình này là **tính giải thích cao**, dễ triển khai và hiệu quả trên dữ liệu có số chiều vừa và nhỏ.

Logistic Regression là mô hình tuyến tính tổng quát cho bài toán phân loại nhị phân. Mô hình giả định log-odds (logit) của xác suất thuộc lớp dương là một hàm tuyến tính của các đặc trưng đầu vào $\mathbf{X}$:

$$\log \left(\frac{P(Y = 1|\mathbf{X})}{1 - P(Y = 1|\mathbf{X})} \right) = \beta_0 + \beta_1 X_1 + \dots + \beta_p X_p$$

Từ đó, xác suất dự đoán được tính thông qua hàm sigmoid:

$$P(Y = 1|\mathbf{X}) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 X_1 + \dots + \beta_p X_p)}}$$

Hàm mất mát và Regularization

Tham số mô hình được ước lượng bằng cách tối đa hóa log-likelihood, tương đương tối thiểu hóa **hàm mất mát log-loss (binary cross-entropy)**:

$$\mathcal{L}(\beta) = - \sum_{i=1}^n [y_i \log(p_i) + (1 - y_i) \log(1 - p_i)]$$

Để kiểm soát độ phức tạp và chống overfitting, các kỹ thuật regularization được áp dụng:

- **L1 Regularization (Lasso):** Thêm penalty $\lambda \sum |\beta_j|$, có tác dụng lựa chọn đặc trưng.
- **L2 Regularization (Ridge):** Thêm penalty $\lambda \sum \beta_j^2$, giúp thu nhỏ hệ số.

Overfitting và Underfitting

- **Underfitting:** Dễ xảy ra do bản chất **tuyến tính** của mô hình. Nếu quan hệ thực giữa đặc trưng và nhãn là phi tuyến phức tạp, Logistic Regression sẽ không thể biểu diễn được, dẫn đến hiệu năng thấp.
- **Overfitting:** Có thể xảy ra khi số đặc trưng lớn so với số mẫu, hoặc khi các hệ số β có giá trị quá lớn. Regularization (L1/L2) là công cụ chính để giảm phương sai và chống overfitting.

Góc nhìn Bayes: Regularization như Prior và Tính Calibrated

Dưới góc nhìn Bayes, việc thêm regularization L2 tương đương với việc đặt một **prior phân phối Gaussian** có trung bình 0 lên các trọng số β . Điều này thể hiện niềm tin tiên nghiệm rằng các hệ số nên nhỏ, trừ khi dữ liệu cung cấp bằng chứng mạnh mẽ ngược lại. Nhờ đó, mô

hình trở nên "thận trọng" hơn, tránh đưa ra các xác suất quá cực đoan (gần 0 hoặc 1) một cách không cần thiết.

Một ưu điểm quan trọng của Logistic Regression là xác suất đầu ra thường **được hiệu chỉnh tốt (well-calibrated)**. Nghĩa là, nếu mô hình dự đoán xác suất gian lận là 0.8 cho một nhóm giao dịch, thì khoảng 80% trong số đó thực sự là gian lận trên thực tế. Tính chất này xuất phát từ việc hàm sigmoid và log-loss được thiết kế phù hợp để ước lượng xác suất thực, giúp Logistic Regression trở thành công cụ đáng tin cậy cho các quyết định dựa trên rủi ro.

3.5 RANDOM FOREST

Giới thiệu thuật toán Random Forest

- **Nguồn gốc:** Random Forest được đề xuất bởi **Leo Breiman** vào năm 2001 [?], dựa trên ý tưởng kết hợp nhiều cây quyết định (Decision Trees) thông qua kỹ thuật **bootstrap aggregating (bagging)** và chọn đặc trưng ngẫu nhiên.
- **Bài toán áp dụng:** Thuật toán này được sử dụng chủ yếu cho cả bài toán **phân loại (classification)** và **hồi quy (regression)**. Trong phát hiện gian lận, Random Forest đặc biệt hiệu quả nhờ khả năng xử lý dữ liệu không cân bằng, giảm thiểu hiện tượng overfitting so với một cây quyết định đơn lẻ, và cho độ chính xác cao nhờ cơ chế voting hoặc trung bình hóa từ nhiều cây.

Nguyên lý mô hình cây quyết định và Ensemble

Random Forest là một mô hình **ensemble** được xây dựng từ nhiều cây quyết định độc lập. Mỗi cây được huấn luyện trên một tập con bootstrap (lấy mẫu có hoàn lại) của dữ liệu huấn luyện và tại mỗi nút chia chỉ xét một tập con ngẫu nhiên của các đặc trưng. Dự đoán cuối cùng là kết quả bỏ phiếu (voting) hoặc trung bình của tất cả các cây.

Với bài toán phân loại, xác suất dự đoán được tính bằng trung bình xác suất của các cây thành phần:

$$P(Y = 1|X) = \frac{1}{T} \sum_{t=1}^T P_t(Y = 1|X)$$

trong đó T là số lượng cây.

Ưu điểm trong dữ liệu phi tuyến và mất cân bằng

Nhờ cấu trúc cây quyết định, Random Forest có khả năng mô hình hóa các mối quan hệ **phi tuyến và tương tác phức tạp** giữa các đặc trưng mà không cần biến đổi đặc biệt. Đồng thời, việc kết hợp nhiều cây giúp **giảm phương sai** đáng kể so với một cây đơn lẻ, tăng độ ổn định và khả năng tổng quát hóa.

Trong các bài toán dữ liệu mất cân bằng, Random Forest có thể kết hợp với **trọng số lớp (class_weight)** để tăng mức độ nhạy đối với lớp thiểu số (gian lận), hoặc kết hợp với các kỹ thuật resampling như SMOTE.

Các siêu tham số quan trọng

Các siêu tham số chính của Random Forest bao gồm:

- **n_estimators:** Số lượng cây trong rừng.
- **max_depth:** Độ sâu tối đa của mỗi cây.
- **min_samples_split:** Số mẫu tối thiểu để chia một nút.
- **min_samples_leaf:** Số mẫu tối thiểu tại một lá.

- **max_features**: Số lượng đặc trưng được xét tại mỗi lần chia.

Những siêu tham số này quyết định trực tiếp độ phức tạp và khả năng tổng quát hóa của mô hình.

Góc nhìn Bayes: Tập hợp các chuyên gia độc lập

Dưới góc nhìn Bayes, Random Forest có thể được hình dung như một tập hợp nhiều "chuyên gia" (cây quyết định) độc lập, mỗi người được đào tạo trên một góc nhìn hơi khác nhau về dữ liệu (bootstrap sample và subset feature) [?]. Việc lấy trung bình dự đoán từ nhiều chuyên gia tương tự như lấy trung bình Monte Carlo trên phân phối hậu nghiệm của các mô hình.

Điều này dẫn đến hai đặc tính xác suất quan trọng: 1. **Tính ổn định và thận trọng**: Random Forest hiếm khi đưa ra xác suất cực đoan (0% hoặc 100%) vì cần sự đồng thuận của hầu hết các cây. Xác suất đầu ra thường tập trung ở vùng trung bình (0.2–0.8), phản ánh sự không chắc chắn một cách hợp lý [?]. 2. **Giảm overfitting**: Các lỗi ngẫu nhiên của từng cây có xu hướng triệt tiêu lẫn nhau khi lấy trung bình, giúp mô hình tổng thể ổn định và ít nhạy cảm với nhiễu trong dữ liệu huấn luyện.

3.6 EXTREME GRADIENT BOOSTING (XGBOOST)

Giới thiệu thuật toán XGBoost

- **Nguồn gốc**: XGBoost (Extreme Gradient Boosting) được đề xuất bởi **Tianqi Chen** và **Carlos Guestrin** vào năm 2016, dựa trên nền tảng của thuật toán Gradient Boosting nhưng được tối ưu hóa về tốc độ và hiệu suất thông qua các kỹ thuật như regularization, xử lý dữ liệu thiếu, và song song hóa.
- **Bài toán áp dụng**: Thuật toán này được sử dụng rộng rãi cho cả bài toán **phân loại (classification)** và **hồi quy (regression)**. Trong lĩnh vực phát hiện gian lận, XGBoost thường cho kết quả vượt trội nhờ khả năng xử lý dữ liệu lớn, tránh overfitting thông qua regularization, và tối ưu hóa hiệu suất tính toán. Đây là một trong những mô hình mạnh mẽ nhất trong các cuộc thi học máy và ứng dụng thực tế.

Nguyên lý Boosting

Khác với Random Forest (bagging – song song), XGBoost thuộc họ **boosting (tuần tự)**. Mô hình được xây dựng bằng cách cộng dồn tuần tự nhiều cây quyết định yếu (weak learners). Mỗi cây mới được huấn luyện để sửa chữa sai sót (phần dư) của tổng hợp các cây trước đó.

Dự đoán của mô hình sau t bước là:

$$\hat{y}_i^{(t)} = \hat{y}_i^{(t-1)} + \eta f_t(x_i)$$

với η là learning rate và f_t là cây quyết định tại bước t .

Hàm mục tiêu và Regularization

XGBoost tối ưu một hàm mục tiêu bao gồm cả hàm mất mát (loss function) và một thành phần regularization phạt độ phức tạp của cây:

$$\mathcal{L}^{(t)} = \sum_{i=1}^n l(y_i, \hat{y}_i^{(t-1)} + f_t(x_i)) + \Omega(f_t)$$

$$\Omega(f) = \gamma T + \frac{1}{2} \lambda \|w\|^2$$

trong đó T là số lá, w là giá trị tại lá, γ và λ là các hệ số regularization. Thiết kế này cho phép XGBoost kiểm soát overfitting một cách chủ động.

Các siêu tham số quan trọng

Các siêu tham số chính của XGBoost bao gồm:

- `n_estimators` / `num_boost_round`: Số lượng cây.
- `learning_rate` (`eta`): Tốc độ học.
- `max_depth`: Độ sâu tối đa của cây.
- `subsample`: Tỷ lệ mẫu dùng cho mỗi cây.
- `colsample_bytree`: Tỷ lệ đặc trưng dùng cho mỗi cây.
- `gamma`, `reg_alpha`, `reg_lambda`: Các tham số regularization.
- `scale_pos_weight`: Tham số quan trọng để xử lý dữ liệu mất cân bằng.

Ưu điểm và rủi ro Overfitting

Ưu điểm:

- Hiệu năng dự đoán rất cao, thường vượt trội so với các phương pháp khác.
- Tích hợp sẵn cơ chế regularization mạnh.
- Xử lý hiệu quả dữ liệu lớn và có khả năng tự xử lý giá trị thiếu.

Rủi ro Overfitting: Do cơ chế boosting tập trung sửa lỗi liên tục, XGBoost rất dễ overfit nếu số cây quá lớn, learning rate quá cao hoặc cây quá phức tạp. Do đó, việc sử dụng **early stopping** dựa trên tập validation và tuning cẩn thận các tham số regularization là rất quan trọng.

Góc nhìn Bayes: Xu hướng overconfidence và nhu cầu calibration

Dưới góc nhìn Bayes, quá trình boosting có thể được xem như việc liên tục cập nhật niềm tin (posterior) với giả định mô hình ngày càng chính xác. Điều này dẫn đến một đặc tính quan trọng: XGBoost có xu hướng trở nên **quá tự tin (over-confident)**. Mô hình có thể đẩy xác suất dự đoán về rất gần 0 hoặc 1 ngay cả khi bằng chứng không thực sự mạnh, nhằm tối thiểu hóa hàm log-loss.

Hệ quả là, mặc dù tối ưu log-loss, xác suất đầu ra của XGBoost thường **chưa được hiệu chỉnh tốt (poorly calibrated)**. Nó có thể dự đoán 0.9 cho những trường hợp mà xác suất thực chỉ khoảng 0.7. Do đó, trong các ứng dụng yêu cầu xác suất tin cậy để ra quyết định (như phát hiện gian lận), việc áp dụng thêm bước **calibration** (ví dụ: Platt scaling, isotonic regression) sau khi huấn luyện XGBoost là cần thiết.

3.7 So sánh tổng quan ba mô hình dưới góc nhìn xác suất và hiệu năng

Dựa trên phân tích lý thuyết và góc nhìn Bayes, bảng so sánh sau đây tóm tắt đặc điểm chính của ba mô hình:

Tiêu chí	Logistic Regression	Random Forest	XGBoost
Tiếp cận	Tuyến tính	Ensemble (Bagging)	Ensemble (Boosting)
Ưu điểm chính	Diễn giải tốt, xác suất calibrated, ổn định, nhanh.	Mạnh với phi tuyến, ổn định, ít tuning, chống overfitting tốt.	Hiệu năng cao nhất, xử lý phi tuyến mạnh, regularization linh hoạt.
Nhược điểm chính	Không mô hình được quan hệ phi tuyến phức tạp.	Khó diễn giải trực tiếp, chi phí tính toán và lưu trữ cao.	Dễ overfit, tuning phức tạp, xác suất cần calibration.
Xử lý mất cân bằng	Class_weight, điều chỉnh ngưỡng.	Class_weight, resampling, OOB.	Scale_pos_weight, resampling, focal loss (tùy chỉnh).
Góc nhìn xác suất	Calibrated tốt, thận trọng, prior Gaussian.	Calibrated khá tốt, thận trọng, trung bình nhiều mô hình.	Có xu hướng overconfident, cần calibration thêm.
Phù hợp bài toán gian lận	Mô hình nền, baseline, yêu cầu diễn giải cao.	Ứng dụng tổng quát, ổn định, dễ triển khai.	Hiệu năng tối ưu, dữ liệu lớn, sẵn sàng tuning kỹ.

Kết luận cho lựa chọn mô hình: Cả ba mô hình đều có vai trò trong pipeline phát hiện gian lận. Logistic Regression cung cấp nền tảng diễn giải và benchmark. Random Forest là lựa chọn ổn định, ít rủi ro. XGBoost là ứng cử viên cho hiệu năng cao nhất, với điều kiện được tối ưu hóa cẩn thận và hiệu chỉnh xác suất nếu cần. Trong đề tài này, cả ba mô hình sẽ được triển khai, đánh giá và so sánh toàn diện để tìm ra mô hình phù hợp nhất với đặc thù của tập dữ liệu PaySim.

4 CHƯƠNG 4: THIẾT KẾ THỰC NGHIỆM VÀ XÂY DỰNG MÔ HÌNH

4.1 Tiền xử lý dữ liệu (Feature Engineering)

4.1.1 Phương pháp luận – Cơ sở thiết kế đặc trưng (Feature Design Rationale)

Quy trình xây dựng đặc trưng trong đề tài được thiết kế nhằm chuyển dịch có hệ thống các hiểu biết về hành vi gian lận tín dụng thành các tín hiệu định lượng mà mô hình Machine Learning có thể khai thác. Thay vì tạo đặc trưng một cách tùy ý, mỗi biến được xây dựng đều xuất phát từ các quan sát nghiệp vụ và đặc điểm hành vi giao dịch, qua đó đảm bảo không gian đặc trưng vừa có khả năng phân biệt tốt, vừa duy trì được tính diễn giải.

A) Nguyên tắc bảo toàn kế toán (Tính toàn vẹn dòng tiền)

Động cơ: Trong các giao dịch hợp lệ, mối quan hệ giữa số dư trước, số dư sau và số tiền giao dịch phải tuân theo logic kế toán cơ bản.

Cách xây dựng: $\text{balance_diff} = \text{oldbalanceOrg} - \text{newbalanceOrig} - \text{amount} - \text{errorBalanceDest} - \text{newbalanceDest} - \text{oldbalanceDest} - \text{amount}$

Ý nghĩa: Các đặc trưng này mã hóa trực tiếp mức độ vi phạm logic tài chính, đóng vai trò là tín hiệu mạnh phản ánh khả năng tồn tại gian lận hoặc bất thường trong giao dịch.

B) Độ lớn có ý nghĩa (Khuếch đại tín hiệu bất thường)

Động cơ: Mức độ nghiêm trọng của một vi phạm thường quan trọng hơn hướng vi phạm trong việc phát hiện gian lận.

Cách xây dựng: $-abs_balance_diff = |balance_diff| - abs_errorBalanceDest = |errorBalanceDest|$

Ý nghĩa: Việc sử dụng giá trị tuyệt đối giúp bảo toàn cường độ bất thường, đồng thời phù hợp với giả định của mô hình tuyến tính và hiệu quả với các mô hình dựa trên cây.

C) Chuẩn hóa theo ngữ cảnh tài khoản (Bất thường tương đối)

Động cơ: Mức độ rủi ro của một giao dịch cần được đánh giá tương đối so với bối cảnh tài chính của tài khoản, thay vì chỉ dựa trên giá trị tuyệt đối.

Cách xây dựng: $amount_ratio_org = amount / (oldbalanceOrg + 1)$

Ý nghĩa: Đặc trưng này giúp mô hình phân biệt giữa các giao dịch có giá trị lớn nhưng hợp lý với tài khoản lớn và các giao dịch có giá trị tương đối bất thường đối với tài khoản nhỏ.

D) Phát hiện trạng thái biên của tài khoản

Động cơ: Các tài khoản có số dư bằng không thường thể hiện hành vi giao dịch khác biệt và có thể tiềm ẩn rủi ro gian lận cao hơn.

Cách xây dựng: $-is_empty_orig = (oldbalanceOrg == 0) - is_empty_dest = (oldbalanceDest == 0)$

Ý nghĩa: Các biến nhị phân này cung cấp điểm phân tách rõ ràng cho các mô hình dựa trên cây và hỗ trợ khai thác các tương tác phi tuyến giữa trạng thái tài khoản và hành vi giao dịch.

E) Ổn định hóa phân phối giá trị giao dịch

Động cơ: Giá trị giao dịch trong dữ liệu tài chính thường có phân phối lệch phải với đuôi dài, dễ gây mất ổn định cho quá trình huấn luyện.

Cách xây dựng: $\log_amount = \log(1 + amount)$

Ý nghĩa: Phép biến đổi log giúp giảm ảnh hưởng của các giá trị cực đoan, cải thiện độ ổn định thống kê và đáp ứng tốt hơn các giả định của mô hình tuyến tính.

F) Tín hiệu heuristic tổng hợp

Động cơ: Sự kết hợp của nhiều dấu hiệu bất thường nhỏ có thể làm gia tăng đáng kể mức độ rủi ro của giao dịch.

Cách xây dựng: $red_flag = (abs_balance_diff >) \vee (abs_errorBalanceDest >) \vee (amount_ratio_org > 0.9)$

Ý nghĩa: Đặc trưng tổng hợp này đóng vai trò như một tín hiệu dẫn hướng, giúp mô hình tập trung vào các vùng rủi ro cao mà không áp đặt các quy tắc cứng nhắc, phù hợp với cách tiếp cận giám sát yếu.

I) Rời rạc hóa thời gian

Động cơ: Hành vi gian lận có thể thể hiện tính chu kỳ theo thời gian, chẳng hạn theo giờ hoặc theo ngày.

Cách xây dựng: $hour = step \% 24; day = step // 24$

Ý nghĩa: Các đặc trưng thời gian tường minh cho phép mô hình khai thác yếu tố thời vụ và bối cảnh thời gian mà không cần sử dụng các mô hình chuỗi thời gian phức tạp.

4.1.2 Tính phù hợp của đặc trưng đối với mô hình

Tập đặc trưng được thiết kế có chủ đích để phù hợp với cả mô hình tuyến tính và phi tuyến. Đối với Logistic Regression, các đặc trưng được chuẩn hóa và biến đổi nhằm tăng khả năng phân tách tuyến tính. Đối với Random Forest và XGBoost, các đặc trưng giữ lại độ lớn thô, tỷ lệ và cờ nhị phân, tạo điều kiện cho mô hình học các tương tác phi tuyến và quan hệ bậc cao.

4.1.3 Loại bỏ các biến định danh không mang thông tin hành vi

Các biến định danh tài khoản như nameOrig và nameDest được loại bỏ khỏi tập đặc trưng do mang tính hồ sơ cao và có nguy cơ gây quá khớp thông qua rò rỉ thông tin định danh. Việc loại

bổ này giúp mô hình học được các mẫu gian lận mang tính tổng quát, thay vì ghi nhớ hành vi của các cá thể cụ thể.

4.1.4 Đánh giá và loại bỏ rò rỉ dữ liệu (Data Leakage Assessment)

Để đảm bảo tính hợp lệ của các mô hình, mọi biến đều được đánh giá nguy cơ rò rỉ dữ liệu (data leakage) dựa trên ba tiêu chí: (1) thông tin có sẵn tại thời điểm dự đoán trong thực tế, (2) mối quan hệ nhân quả với nhãn gian lận, và (3) nguy cơ tạo shortcut learning. Bảng 1 tổng hợp kết quả đánh giá và quyết định giữ/loại cho từng biến.

Bảng 1: Đánh giá rò rỉ dữ liệu và quyết định lựa chọn đặc trưng

Biến	Loại leakage	Quyết định	Lý do
oldbalanceOrg, newbalanceOrig	Temporal + system	Loại bỏ	Phản ánh số dư sau giao dịch, không có tại thời điểm dự đoán
oldbalanceDest, newbalanceDest	Severe leakage	Loại bỏ	Tương tự, liên quan đến tài khoản đích sau giao dịch
isFlaggedFraud	Label proxy	Loại bỏ	Được gán bởi hệ thống cũ, là proxy trực tiếp của nhãn isFraud
balance_diff, errorBalanceDest	Accounting logic	Loại bỏ	Tính từ các biến leakage trên
abs_balance_diff, abs_errorBalanceDest	Inherited leakage	Loại bỏ	Kế thừa leakage từ biến gốc
amount_ratio_orig	Model-dependent	Loại bỏ (RF, XGB)	Tín hiệu quá rõ ràng, gây shortcut learning; có thể dùng cho LR
red_flag	Composite proxy	Loại bỏ	Tổng hợp từ các biến leakage
is_empty_orig, is_empty_dest	System artifact	Loại bỏ (LR)	Có thể tạo shortcut nếu dùng cùng số dư; giữ lại cho RF/XGB
step	Temporal leakage	Chuyển đổi	Rời rạc hóa thành hour, day để tránh thông tin thứ tự thời gian
type, amount, hour, day, log_amount	An toàn	Giữ lại	Có sẵn tại thời điểm giao dịch, không chứa leakage
isMerchant, isCustomerDest	An toàn	Giữ lại	Thông tin vai trò tài khoản, không phụ thuộc vào kết quả giao dịch

Quy trình kiểm tra leakage được thực hiện như sau:

1. Với mỗi biến, xác định liệu nó có sẵn tại **thời điểm dự đoán** trong thực tế hay không.
2. Kiểm tra tương quan trực tiếp với nhãn **isFraud** – các biến có tương quan quá cao (>0.8) bị nghi ngờ là proxy của nhãn.
3. Đánh giá dựa trên **domain knowledge**: các biến phản ánh trạng thái sau giao dịch bị loại bỏ.
4. Với các mô hình khác nhau, áp dụng chiến lược lựa chọn nghiêm ngặt hơn cho Logistic Regression do tính nhạy cảm với leakage.

Kết quả cuối cùng, tập đặc trưng cho **Logistic Regression** chỉ giữ lại 7 biến an toàn, trong khi **Random Forest** và **XGBoost** có thể giữ thêm một số biến nhị phân như `is_empty_orig` nhưng vẫn loại bỏ tất cả biến có nguy cơ leakage cao.

4.2 Xây dựng và đánh giá mô hình Logistic Regression

4.2.1 Quy trình xây dựng mô hình

Quá trình xây dựng mô hình Logistic Regression trong đề tài được thực hiện theo một pipeline có kiểm soát, bao gồm các bước tuần tự sau:

1. Chuẩn bị dữ liệu sau tiền xử lý và xây dựng đặc trưng (mục 4.1)
2. Loại bỏ các biến không phù hợp cho mô hình Logistic Regression
3. Chia dữ liệu thành tập huấn luyện và tập kiểm tra
4. Chuẩn hóa và mã hóa đặc trưng
5. Huấn luyện mô hình Logistic Regression cơ sở
6. Đánh giá mô hình bằng các chỉ số phù hợp
7. Tinh chỉnh siêu tham số và ngưỡng phân loại

4.2.2 Lựa chọn và loại bỏ các đặc trưng đầu vào

Sau bước xây dựng đặc trưng, không phải tất cả các biến đều được sử dụng trực tiếp cho mô hình Logistic Regression. Việc loại bỏ đặc trưng được thực hiện có chủ đích, dựa trên ba tiêu chí chính: tránh rò rỉ dữ liệu, giảm nguy cơ overfitting, và phù hợp với giả định của mô hình tuyến tính.

1. **Loại bỏ các biến định danh:** Các biến `nameOrig` và `nameDest` được loại bỏ vì đây là các biến định danh tài khoản, có số lượng giá trị duy nhất rất lớn và không phản ánh hành vi giao dịch mang tính tổng quát.
2. **Loại bỏ các biến phản ánh trực tiếp trạng thái sau giao dịch:** Các biến như `newbalanceOrig` và `newbalanceDest` không được sử dụng trực tiếp trong mô hình Logistic Regression. Lý do là các biến này phản ánh trạng thái tài khoản sau giao dịch và có mối liên hệ chặt chẽ với nhãn gian lận trong cơ chế sinh dữ liệu PaySim.
3. **Loại bỏ các đặc trưng tổng hợp mang tính heuristic:** Đặc trưng tổng hợp như `red_flag`, mặc dù hữu ích trong phân tích và một số mô hình phi tuyến, không được sử dụng trong Logistic Regression.
4. **Giữ lại các đặc trưng phù hợp với mô hình tuyến tính:** Các đặc trưng được giữ lại cho Logistic Regression bao gồm:
 - Các biến định lượng đã được chuẩn hóa (ví dụ: `log_amount`, các tỷ lệ)
 - Các đặc trưng sai lệch số dư ở dạng liên tục
 - Các biến phân loại sau khi được mã hóa one-hot

4.2.3 Chia dữ liệu huấn luyện và kiểm tra

Dữ liệu được chia thành tập huấn luyện và tập kiểm tra theo tỷ lệ 80/20, sử dụng stratified sampling để bảo toàn tỷ lệ gian lận giữa hai tập. Cách chia này đặc biệt quan trọng trong bối cảnh dữ liệu mất cân bằng, nhằm tránh hiện tượng tập kiểm tra không đại diện cho phân phối thực tế.

4.2.4 Huấn luyện mô hình Logistic Regression cơ sở

Mô hình Logistic Regression được huấn luyện với các thiết lập sau:

- Sử dụng `class_weight = "balanced"` để tăng trọng số cho lớp gian lận - Chuẩn hóa các biến số bằng `StandardScaler` - Tăng số vòng lặp tối đa để đảm bảo hội tụ

Mô hình cơ sở này đóng vai trò làm chuẩn so sánh cho các cấu hình tối ưu hơn và các mô hình phi tuyến trong các phần tiếp theo.

4.2.5 Kết quả đánh giá mô hình cơ sở

Mô hình Logistic Regression cơ sở đạt:

- ROC-AUC xấp xỉ 0.97, cho thấy khả năng phân biệt tốt giữa giao dịch gian lận và không gian lận - Recall cao đối với lớp gian lận - Precision thấp, phản ánh việc mô hình dự đoán dư thừa gian lận trong bối cảnh dữ liệu mất cân bằng

Ma trận nhầm lẫn cho thấy mô hình ưu tiên giảm bỏ sót gian lận hơn là giảm cảnh báo nhầm.

```
Classification Report:
              precision    recall  f1-score   support

     0             1.00      0.86      0.92     63544
     1             0.15      0.94      0.26      1643

 accuracy              0.86     65187
 macro avg             0.57      0.90      0.59     65187
weighted avg             0.98      0.86      0.91     65187

Confusion Matrix:
[[54684  8860]
 [   105 1538]]
ROC-AUC: 0.9671820845557465
```

Hình 4.1: Kết quả đánh giá mô hình cơ sở

4.3 Tối ưu hóa mô hình: Resampling và điều chỉnh ngưỡng phân loại

Một trong những thách thức lớn nhất khi huấn luyện mô hình Logistic Regression cho bài toán phát hiện gian lận là vấn đề mất cân bằng dữ liệu nghiêm trọng (tỷ lệ gian lận chỉ 2.52%). Phần này trình bày quy trình tối ưu hóa mô hình thông qua hai bước chính: (1) lựa chọn phương pháp xử lý mất cân bằng tối ưu, và (2) điều chỉnh ngưỡng phân loại phù hợp với yêu cầu nghiệp vụ.

4.3.1 Đánh giá các phương pháp xử lý mất cân bằng

Năm phương pháp resampling phổ biến được đánh giá để xác định phương pháp tối ưu cho bài toán. Bảng 2 trình bày kết quả so sánh chi tiết:

Bảng 2: So sánh hiệu suất của các phương pháp resampling trên Logistic Regression

Phương pháp	ROC-AUC	PR-AUC	Precision	Recall	F1-Score
Không resampling	0.9672	0.5360	0.1479	0.9361	0.2555
SMOTE	0.9671	0.5366	0.1479	0.9373	0.2556
SMOTE-ENN	0.9671	0.5356	0.1503	0.9367	0.2590
SMOTE-Tomek	0.9671	0.5368	0.1481	0.9373	0.2557
Undersampling	0.9658	0.5441	0.1457	0.9385	0.2523

Phân tích và lựa chọn:

- **SMOTE-ENN đạt F1-Score cao nhất** (0.2590), cho thấy sự kết hợp giữa tạo mẫu tổng hợp (SMOTE) và làm sạch biên (ENN) mang lại hiệu quả tốt nhất.
- **Các phương pháp SMOTE-based** giữ ổn định ROC-AUC (0.9671), trong khi under-sampling làm giảm nhẹ chỉ số này.
- **Undersampling đạt PR-AUC cao nhất** nhưng F1-Score thấp, cho thấy phương pháp này không phù hợp với mục tiêu cân bằng giữa Precision và Recall.

4.3.2 Phân tích sâu ảnh hưởng của SMOTE-ENN

SMOTE-ENN được lựa chọn làm phương pháp tối ưu. Bảng 3 phân tích chi tiết sự thay đổi về hiệu suất và ma trận nhầm lẫn:

Bảng 3: Phân tích ảnh hưởng của SMOTE-ENN đến hiệu suất và confusion matrix

Chỉ số	Trước resampling	Sau SMOTE-ENN	Thay đổi
Metrics chính			
ROC-AUC	0.9672	0.9667	-0.05%
PR-AUC	0.5360	0.5424	+1.20%
Precision	0.1479	0.5707	+285.85%
Recall	0.9361	0.5648	-39.66%
F1-Score	0.2555	0.5678	+122.25%
Confusion Matrix (Lớp Gian lận)			
True Positive (TP)	1538	928	-39.66%
False Negative (FN)	105	715	+581.90%
False Positive (FP)	8860	698	-92.12%
True Negative (TN)	54684	62846	+14.95%

Nhận xét quan trọng:

1. **Precision tăng vượt trội** (285.85%): SMOTE-ENN giúp mô hình giảm mạnh cảnh báo sai, từ 8860 xuống còn 698 false positives.
2. **Trade-off cần thiết**: Việc tăng Precision đi kèm với giảm Recall (từ 93.61% xuống 56.48%), thể hiện qua việc false negatives tăng từ 105 lên 715.

3. **F1-Score cải thiện mạnh** (122.25%): Cho thấy sự cân bằng tổng thể được cải thiện đáng kể.
4. **PR-AUC tăng nhẹ**: Phản ánh hiệu quả tốt hơn trong việc phát hiện lớp thiểu số (gian lận).

4.3.3 Kết luận và đề xuất triển khai

Dựa trên phân tích toàn diện, có thể đưa ra các kết luận và đề xuất quan trọng:

- **Phương pháp tối ưu**: SMOTE-ENN là lựa chọn tốt nhất cho Logistic Regression trong bài toán này, giúp cải thiện F1-Score 122.25% so với baseline không resampling.
- **Ngưỡng phân loại linh hoạt**: Không tồn tại ngưỡng "tốt nhất" duy nhất. Việc lựa chọn ngưỡng phụ thuộc vào chiến lược nghiệp vụ và nguồn lực sẵn có.
- **Đề xuất triển khai thực tế**:
 1. **Hệ thống đa tầng**: Kết hợp nhiều ngưỡng trong cùng hệ thống:
 - Tầng 1 (Threshold = 0.1974): Cảnh báo sơ bộ cho nhân viên xem xét.
 - Tầng 2 (Threshold = 0.8257): Tự động chặn các giao dịch có rủi ro cao.
 - Tầng 3 (Threshold = 0.9000): Ưu tiên điều tra chuyên sâu.
 2. **Điều chỉnh động**: Có thể điều chỉnh ngưỡng theo thời gian thực dựa trên tải làm việc của nhân viên và mức độ ưu tiên.
 3. **Giám sát liên tục**: Theo dõi hiệu suất mô hình theo thời gian và điều chỉnh khi có sự thay đổi trong hành vi gian lận.

Quá trình tối ưu hóa chứng minh rằng hiệu suất mô hình Logistic Regression không chỉ phụ thuộc vào thuật toán mà còn vào chiến lược xử lý dữ liệu và lựa chọn ngưỡng phù hợp với bối cảnh ứng dụng thực tế.

4.3.4 Top 10 đặc trưng quan trọng nhất

Bảng 4 trình bày 10 đặc trưng có hệ số lớn nhất sau khi huấn luyện mô hình Logistic Regression với SMOTE-ENN. Hệ số dương cho thấy biến làm tăng xác suất gian lận, hệ số âm cho thấy biến làm giảm xác suất gian lận.

Bảng 4: Top 10 đặc trưng quan trọng nhất - Logistic Regression với SMOTE-ENN

Đặc trưng	Hệ số	Diễn giải nghiệp vụ
type_TRANSFER	+10.39	Giao dịch chuyển khoản - Yếu tố quan trọng nhất, phù hợp với thực tế gian lận thường tập trung vào chuyển tiền.
type_CASH_OUT	+9.66	Giao dịch rút tiền - Kênh gian lận phổ biến thứ hai, thường đi kèm với chuyển khoản trong chuỗi gian lận.
type_PAYMENT	-3.35	Giao dịch thanh toán - Có hệ số âm mạnh, cho thấy đây là loại giao dịch an toàn, ít bị gian lận.
is_empty_orig	-1.75	Tài khoản gốc trống - Tài khoản có số dư = 0 ít có khả năng là nguồn phát sinh gian lận.
amount_ratio_org	-1.04	Tỷ lệ giao dịch/số dư gốc - Tỷ lệ cao không nhất thiết là dấu hiệu gian lận trong mô hình tuyến tính.
amount	+0.88	Giá trị giao dịch - Giao dịch giá trị cao có nguy cơ gian lận cao hơn.
is_empty_dest	+0.66	Tài khoản đích trống - Có thể là dấu hiệu bất thường, tài khoản mới hoặc tài khoản trung gian.
type_DEBIT	-0.59	Giao dịch ghi nợ - Ít liên quan đến gian lận.
hour	-0.51	Khung giờ giao dịch - Một số khung giờ (đặc biệt ban đêm) có tỷ lệ gian lận thấp hơn.
day	+0.49	Ngày trong tháng - Một số ngày (cuối tháng, đầu tháng) có tỷ lệ gian lận cao hơn.

4.3.5 Phân tích theo nhóm đặc trưng

Để hiểu rõ hơn về cơ chế phát hiện gian lận, các đặc trưng được nhóm thành 4 danh mục chính:


- **Nhóm loại giao dịch:** Chiếm 3/10 vị trí đầu, khẳng định **TRANSFER** và **CASH_OUT** là hai kênh gian lận chủ yếu.
- **Nhóm hành vi tài khoản:** **is_empty_orig** và **is_empty_dest** cho thấy trạng thái tài khoản có ý nghĩa quan trọng trong đánh giá rủi ro.
- **Nhóm giá trị giao dịch:** **amount** có tác động dương nhưng không quá mạnh, cho thấy gian lận không chỉ phụ thuộc vào giá trị tuyệt đối.
- **Nhóm yếu tố thời gian:** **hour** và **day** xác nhận tính thời vụ của gian lận, phù hợp với phân tích EDA.

4.3.6 So sánh hệ số trước và sau Resampling

Một phân tích thú vị là so sánh sự thay đổi hệ số trước và sau khi áp dụng SMOTE-ENN:

Bảng 5: So sánh hệ số đặc trưng trước/sau resampling

Đặc trưng	Trước SMOTE-ENN	Sau SMOTE-ENN	Thay đổi (%)
type_TRANSFER	+8.52	+10.39	+21.95%
type_CASH_OUT	+7.87	+9.66	+22.74%
type_PAYMENT	-0.51	-3.35	+556.86%
is_empty_orig	-1.34	-1.75	+30.60%
amount	+1.06	+0.88	-16.98%



Hình 4.2: So sánh kết quả Logistic Regression trước và sau resampling

Nhận xét quan trọng:

- Các biến quan trọng nhất (**type_TRANSFER**, **type_CASH_OUT**) đều **tăng hệ số** sau resampling, cho thấy mô hình trở nên **tự tin hơn** trong việc sử dụng các biến này.
- **type_PAYMENT** thay đổi mạnh nhất (từ -0.51 lên -3.35), cho thấy sau khi cân bằng dữ liệu, mô hình nhận diện rõ hơn đây là loại giao dịch an toàn.
- **amount** giảm nhẹ hệ số, phản ánh việc resampling giúp mô hình ít phụ thuộc hơn vào biến số tuyệt đối.

Hình ?? trực quan hóa sự so sánh giữa mô hình gốc và mô hình sau khi áp dụng SMOTE-ENN. Có thể quan sát thấy:

1. **Đường cong ROC (Trái trên):** Cả hai mô hình đều đạt AUC 0.967, cho thấy resampling không làm thay đổi đáng kể khả năng phân biệt tổng quát của mô hình.
2. **Đường cong Precision-Recall (Phải trên):** Mô hình với SMOTE-ENN (AP = 0.542) có cải thiện nhẹ so với mô hình gốc (AP = 0.536), đặc biệt ở vùng recall trung bình, phản ánh hiệu quả của việc cân bằng dữ liệu.
3. **Ma trận nhầm lẫn (Dưới cùng):** Cho thấy sự thay đổi trong phân bố dự đoán sau resampling, với xu hướng giảm false negatives nhưng có thể tăng false positives trong một số trường hợp.

Kết hợp phân tích bảng hệ số và hình ảnh minh họa cho thấy resampling giúp mô hình Logistic Regression **điều chỉnh trọng số đặc trưng** theo hướng phản ánh rõ hơn bản chất của bài toán trong điều kiện dữ liệu cân bằng, mặc dù không thay đổi đáng kể các chỉ số tổng quan như ROC-AUC.

4.3.7 Diễn giải nghiệp vụ và đề xuất

Dựa trên phân tích hệ số, có thể đưa ra các đề xuất nghiệp vụ:

1. **Ưu tiên giám sát:** Tập trung giám sát các giao dịch **TRANSFER** và **CASH_OUT**, đặc biệt khi kết hợp với các yếu tố thời gian bất thường.
2. **Quy tắc nghiệp vụ đơn giản:** Có thể xây dựng quy tắc cảnh báo sơ bộ: "*Nếu giao dịch là TRANSFER hoặc CASH_OUT, cần xem xét thêm các yếu tố khác*".
3. **Giảm cảnh báo sai:** Các giao dịch **PAYMENT** có thể được xử lý với mức độ ưu tiên thấp hơn.

Kết luận, Logistic Regression không chỉ là mô hình baseline mà còn là công cụ diễn giải mạnh mẽ, cung cấp insights nghiệp vụ có giá trị cho bài toán phát hiện gian lận.

4.3.8 Tổng kết Logistic Regression

Logistic Regression cho thấy hiệu quả tốt trong vai trò mô hình nền, với khả năng diễn giải cao và quy trình huấn luyện minh bạch. Tuy nhiên, các hạn chế về khả năng mô hình hóa quan hệ phi tuyến cho thấy sự cần thiết phải sử dụng các mô hình mạnh hơn như Random Forest và XGBoost trong các phần tiếp theo.

4.4 Xây dựng và đánh giá mô hình Random Forest

4.4.1 Quy trình thực nghiệm tổng quát

Quy trình xây dựng và đánh giá mô hình Random Forest được thực hiện theo các bước sau:

1. Sử dụng tập dữ liệu đã tiền xử lý và xây dựng đặc trưng (mục 4.1)
2. Lựa chọn tập đặc trưng phù hợp cho mô hình cây quyết định
3. Chia dữ liệu thành tập huấn luyện và tập kiểm tra theo tỷ lệ 80/20 (stratified)
4. Huấn luyện mô hình Random Forest cơ sở
5. Đánh giá hiệu suất mô hình
6. Xử lý mất cân bằng dữ liệu bằng các kỹ thuật resampling
7. Tối ưu siêu tham số bằng framework Optuna
8. Tối ưu ngưỡng phân loại và đánh giá mô hình cuối cùng

4.4.2 Thiết lập mô hình Random Forest

Khác với Logistic Regression, Random Forest là mô hình phi tuyến dựa trên tập hợp các cây quyết định nên **không yêu cầu chuẩn hóa dữ liệu**. Mô hình này được lựa chọn nhờ ba ưu điểm chính:

1. **Tính robust:** Ít bị ảnh hưởng bởi nhiễu (noise) và các điểm ngoại lai (outliers) so với Logistic Regression.
2. **Khả năng học tương tác phi tuyến:** Tự động phát hiện các mối quan hệ phức tạp giữa các biến (ví dụ: giao dịch lớn kết hợp với khung giờ bất thường).
3. **Không yêu cầu chuẩn hóa:** Giữ nguyên thang đo dữ liệu gốc để khai thác hiệu quả độ lớn và tương tác đặc trưng.

Các biến phân loại được mã hóa one-hot, trong khi các biến số được giữ nguyên. Mô hình Random Forest cơ sở được thiết lập với các tham số chính:

- Số lượng cây (`n_estimators`) = 300
- `class_weight` = "balanced" để giảm ảnh hưởng của dữ liệu mất cân bằng
- Các tham số độ sâu cây và số mẫu tại lá được giữ mặc định trong giai đoạn baseline
- `random_state` = 42 để đảm bảo tính tái lập

4.4.3 Kết quả mô hình Random Forest cơ sở

Mô hình Random Forest cơ sở đạt kết quả khả quan trên tập kiểm tra:

- **ROC-AUC: 0.9518**
- **Precision (lớp gian lận): 0.7551**
- **Recall (lớp gian lận): 0.6476**
- **F1-Score (lớp gian lận): 0.6972**

So với Logistic Regression (F1 = 0.56), Random Forest cải thiện rõ rệt cả Precision và F1-Score, cho thấy khả năng giảm false positives tốt hơn. Ma trận nhầm lẫn cho thấy Random Forest chỉ có 345 cảnh báo nhầm cho lớp không gian lận, trong khi Logistic Regression có tới 1634, phản ánh lợi thế của mô hình phi tuyến trong việc mô hình hóa các tương tác phức tạp.

4.4.4 Phân tích đặc trưng quan trọng

Random Forest cho phép đánh giá tầm quan trọng của các đặc trưng thông qua chỉ số *feature importance*. Kết quả phân tích từ mô hình cơ sở cho thấy:

Đặc trưng	Tầm quan trọng (%)
amount	19.46
log_amount	19.43
day	16.81
hour	14.93
type_TRANSFER	13.91
type_CASH_OUT	6.03

Bảng 6: Top 6 đặc trưng quan trọng nhất của Random Forest cơ sở

Khác với Logistic Regression (chỉ nhấn mạnh TRANSFER và amount), Random Forest **phát hiện biến thời gian (hour, day) lọt top 5 quan trọng nhất**. Điều này cho thấy gian lận có tính chu kỳ thời gian mà mô hình tuyến tính đã bỏ qua, thể hiện ưu điểm của mô hình phi tuyến trong việc khai thác các mẫu hình phức tạp.

4.4.5 Xử lý mất cân bằng dữ liệu bằng Resampling

Bên cạnh việc sử dụng *class weight*, đề tài thử nghiệm năm phương pháp resampling trên tập huấn luyện:

- **SMOTE** (Synthetic Minority Over-sampling Technique)
- **SMOTEENN** (SMOTE + Edited Nearest Neighbors)
- **SMOTETomek** (SMOTE + Tomek Links)
- **Oversampling** (Random Over-sampling)
- **Undersampling** (Random Under-sampling)

Kết quả so sánh cho thấy **SMOTE đạt F1-score cao nhất (0.6903)** và cân bằng tốt giữa Precision (0.7049) và Recall (0.6762). Trong khi đó, Undersampling tuy đạt Recall cao (0.8868) nhưng Precision quá thấp (0.1867), không phù hợp với yêu cầu thực tế về giảm cảnh báo sai.

4.4.6 Tối ưu siêu tham số bằng Optuna

Sau khi lựa chọn SMOTE làm chiến lược resampling, mô hình Random Forest được tối ưu siêu tham số bằng **Optuna** kết hợp **Stratified K-Fold Cross-Validation (5 folds)**. Các tham số được tìm kiếm trong khoảng:

- `n_estimators`: 200-800
- `max_depth`: 5-30
- `min_samples_leaf`: 2-10
- `max_features`: 0.3-1.0

Qua 30 trials, cấu hình tối ưu đạt **ROC-AUC (CV) = 0.9704** với các tham số:

- `n_estimators`: 270
- `max_depth`: 10
- `min_samples_split`: 9
- `min_samples_leaf`: 10
- `max_features`: 0.6548

Kết quả này cho thấy mô hình ổn định hơn và giảm nguy cơ overfitting so với cấu hình mặc định.

4.4.7 Tối ưu ngưỡng phân loại

Tương tự Logistic Regression, Random Forest không sử dụng ngưỡng phân loại mặc định (0.5). Ngưỡng dự đoán được tối ưu dựa trên đường cong Precision-Recall:

- **Ngưỡng tối ưu cho F1-score: 0.6348** ($F1 = 0.6966$)
- **Ngưỡng cho Recall cao (0.9): 0.1049** ($Recall = 0.9002$, $Precision = 0.1770$)

Việc lựa chọn ngưỡng phụ thuộc vào chiến lược kinh doanh: ưu tiên giảm false positives (chọn ngưỡng cao) hay không bỏ sót gian lận (chọn ngưỡng thấp).

4.4.8 Kết quả mô hình Random Forest cuối cùng

Tại ngưỡng tối ưu cho F1-score, mô hình Random Forest cuối cùng đạt:

Chỉ số	Giá trị
ROC-AUC	0.9664
PR-AUC	0.7321
Precision (lớp gian lận)	0.7682
Recall (lớp gian lận)	0.6372
F1-Score (lớp gian lận)	0.6966

Bảng 7: Kết quả mô hình Random Forest cuối cùng

Chỉ số	Baseline	Final Model	Cải thiện
ROC-AUC	0.9629	0.9664	+0.36%
PR-AUC	0.6067	0.7321	+20.67%
Recall	0.8868	0.6372	-28.14%
Precision	0.1867	0.7682	+311.39%
F1-Score	0.3085	0.6966	+125.81%

Bảng 8: So sánh mô hình Random Forest cuối cùng với baseline

4.4.9 So sánh với Baseline

So sánh mô hình cuối cùng (với SMOTE và tuning) với baseline (không resampling) cho thấy cải thiện đáng kể:

Mặc dù Recall giảm, nhưng sự cải thiện vượt trội về Precision (từ 0.1867 lên 0.7682) và F1-Score (tăng 125.81%) chứng tỏ hiệu quả của việc kết hợp SMOTE và tối ưu siêu tham số.

4.4.10 Phân tích đặc trưng quan trọng của mô hình cuối cùng

Sau khi tuning, thứ tự quan trọng của các đặc trưng thay đổi đáng kể:

Đặc trưng	Tầm quan trọng (%)
type_TRANSFER	38.01
hour	13.27
day	12.23
amount	11.85
log_amount	11.04

Bảng 9: Top 5 đặc trưng quan trọng nhất của mô hình Random Forest cuối cùng

Loại giao dịch TRANSFER chiếm tới 38.01% tầm quan trọng, khẳng định đây là yếu tố then chốt trong phát hiện gian lận. Các biến thời gian (hour, day) tiếp tục giữ vị trí quan trọng, cho thấy tính chu kỳ thời gian của hành vi gian lận.

4.4.11 Kết luận về mô hình Random Forest

Kết quả thực nghiệm cho thấy Random Forest cải thiện đáng kể hiệu suất so với Logistic Regression, đặc biệt về Precision và F1-Score. Nhờ khả năng mô hình hóa các quan hệ phi tuyến và tương tác đặc trưng, Random Forest phát hiện được các mẫu hình phức tạp mà mô hình tuyến tính bỏ qua, đặc biệt là yếu tố thời gian.

Mô hình cuối cùng đạt F1-Score 0.6966, cao hơn 24.5% so với Logistic Regression, đồng thời Precision đạt 0.7682 (so với 0.57 của Logistic Regression). Điều này cho thấy Random Forest không chỉ phát hiện tốt hơn mà còn giảm đáng kể số lượng cảnh báo sai, tiết kiệm chi phí kiểm tra thủ công. Kết quả này tạo tiền đề vững chắc cho việc áp dụng các mô hình boosting mạnh hơn như XGBoost trong phần tiếp theo.

4.5 XÂY DỰNG VÀ ĐÁNH GIÁ MÔ HÌNH XGBOOST

4.5.1 Quy trình thực nghiệm tổng quát

Quy trình xây dựng và đánh giá mô hình XGBoost trong đề tài được thực hiện theo các bước sau:

1. Sử dụng tập dữ liệu đã tiền xử lý và chọn lọc đặc trưng phù hợp (mục 4.1)
2. Loại bỏ các đặc trưng có nguy cơ rò rỉ dữ liệu hoặc gây shortcut learning
3. Chia dữ liệu thành tập huấn luyện và tập kiểm tra theo tỷ lệ 80/20 (stratified)
4. Huấn luyện mô hình XGBoost cơ sở với tham số xử lý mất cân bằng
5. Đánh giá hiệu suất mô hình baseline
6. Tối ưu siêu tham số bằng Optuna
7. Thử nghiệm các chiến lược resampling
8. Huấn luyện mô hình cuối cùng và tối ưu ngưỡng phân loại

4.5.2 Thiết lập mô hình XGBoost

XGBoost là mô hình boosting dựa trên cây quyết định, có khả năng học tuần tự từ các lỗi của mô hình trước đó và tích hợp cơ chế regularization nhằm kiểm soát overfitting. Trong đề tài này, XGBoost được kỳ vọng khắc phục các hạn chế còn tồn tại của Random Forest, đặc biệt trong việc tối ưu các mẫu khó phân loại.

Tập đặc trưng đầu vào cho XGBoost được chọn lọc chặt chẽ nhằm tránh rò rỉ dữ liệu, chỉ bao gồm:

- Biến phân loại type (mã hóa one-hot);
- Các biến định lượng và hành vi như amount, log_amount;
- Các biến ngữ cảnh thời gian hour, day;
- Các biến vai trò tài khoản (isMerchant, isCustomerDest).

Để xử lý mất cân bằng dữ liệu, tham số **scale_pos_weight** được thiết lập theo tỷ lệ giữa số mẫu không gian lận và gian lận trong tập huấn luyện.

4.5.3 Kết quả mô hình XGBoost cơ sở

Mô hình XGBoost cơ sở được huấn luyện với số lượng cây trung bình và learning rate mặc định. Kết quả đánh giá trên tập kiểm tra cho thấy:

- **ROC-AUC 0.975** - Recall của lớp gian lận đạt mức cao (0.87) - Precision còn thấp do mô hình ưu tiên phát hiện gian lận

Mã trận nhầm lẫn cho thấy mô hình baseline có xu hướng phát hiện hầu hết các giao dịch gian lận nhưng đánh đổi bằng số lượng cảnh báo nhầm lớn.

Đánh giá mô hình XGBoost cơ bản:

ROC-AUC: 0.9750635835486086

Confusion Matrix:

```
[[59916  3628]
 [   211  1432]]
```

Classification Report:

	precision	recall	f1-score	support
0	0.9965	0.9429	0.9690	63544
1	0.2830	0.8716	0.4273	1643
accuracy			0.9411	65187
macro avg	0.6397	0.9072	0.6981	65187
weighted avg	0.9785	0.9411	0.9553	65187

Hình 4.3: Kết quả đánh giá mô hình XGBoost cơ sở

4.5.4 Tối ưu siêu tham số bằng Optuna

Để cải thiện hiệu suất và kiểm soát độ phức tạp của mô hình, XGBoost được tối ưu siêu tham số bằng **Optuna** kết hợp **Stratified K-Fold Cross-Validation**. Không gian tìm kiếm tập trung vào các tham số quan trọng như:

- số lượng cây (`n_estimators`), - độ sâu cây (`max_depth`), - learning rate, - subsample và `colsample_bytree`, - các tham số regularization (`reg_alpha`, `reg_lambda`).

Kết quả tối ưu cho thấy cấu hình tốt nhất đạt **ROC-AUC (CV) 0.976**, phản ánh khả năng tổng quát hóa tốt và ổn định giữa các fold.

```
# Kết quả tối ưu XGBoost
print("Best ROC-AUC (CV):", study_xgb.best_value)
print("Best params:", study_xgb.best_params)
```

```
Best ROC-AUC (CV): 0.976238899363756
Best params: {'n_estimators': 464, 'max_depth': 8, 'learning_rate':
0.292031438223591, 'subsample': 0.9614681618171416, 'colsample_bytree':
0.9328331701255683, 'min_child_weight': 2, 'gamma': 3.10450780457985,
'reg_alpha': 7.625850948580585, 'reg_lambda': 7.797483967720321}
```

Hình 4.4: Kết quả tối ưu siêu tham số bằng Optuna

4.5.5 Thử nghiệm các chiến lược resampling

Bên cạnh việc sử dụng `scale_pos_weight`, đề tài tiếp tục thử nghiệm các chiến lược **resampling** khác nhau trên tập huấn luyện nhằm cải thiện cân bằng giữa Precision và Recall. Các phương pháp được đánh giá bao gồm SMOTE, SMOTE-ENN, SMOTE-Tomek, oversampling và undersampling.

Kết quả cho thấy **SMOTE** mang lại F1-score cao nhất và sự cân bằng tốt nhất giữa Precision và Recall đối với XGBoost. Do đó, SMOTE được lựa chọn cho các bước huấn luyện tiếp theo.

4.5.6 Huấn luyện mô hình XGBoost cuối cùng

Mô hình XGBoost cuối cùng được huấn luyện với:

- bộ siêu tham số tối ưu từ Optuna, - chiến lược resampling SMOTE, - pipeline tiền xử lý nhất quán.

Kết quả đánh giá trên tập kiểm tra cho thấy mô hình đạt:

- **ROC-AUC 0.972 - Precision 0.82 - Recall 0.65 - F1-score 0.73**

```
Classification Report:
              precision    recall  f1-score   support

     0       0.9910       0.9963       0.9937       63544
     1       0.8198       0.6506       0.7255        1643

 accuracy          0.9876       65187
 macro avg       0.9054       0.8235       0.8596       65187
weighted avg       0.9867       0.9876       0.9869       65187

ROC-AUC: 0.971583
PR-AUC: 0.763503
Recall: 0.6506
Precision: 0.8198
F1-Score: 0.7255

Confusion Matrix:
[[63309   235]
 [  574 1069]]
```

Hình 4.5: Kết quả mô hình XGBoost tối ưu

So với mô hình baseline, Precision và F1-score tăng mạnh, phản ánh hiệu quả của việc kết hợp tối ưu siêu tham số và resampling.

4.5.7 Tối ưu ngưỡng phân loại

Do bài toán gian lận tín dụng yêu cầu cân nhắc giữa việc giảm bỏ sót gian lận và hạn chế cảnh báo nhầm, đề tài tiến hành phân tích và tối ưu ngưỡng phân loại. Hai kịch bản được xem xét:

- Ngưỡng tối ưu theo **F1-score**; - Ngưỡng ưu tiên **Recall cao** (Recall 0.9).

Kết quả cho thấy ngưỡng tối ưu theo F1-score đạt khoảng **0.83**, trong khi ngưỡng ưu tiên Recall cao nằm quanh **0.20**, cho phép linh hoạt điều chỉnh theo yêu cầu vận hành thực tế.

4.5.8 Phân tích đặc trưng quan trọng

Phân tích *feature importance* của mô hình XGBoost cho thấy các đặc trưng quan trọng nhất bao gồm:

- Loại giao dịch **PAYMENT**, **TRANSFER** và **CASH_OUT**; - Vai trò tài khoản (is-CustomerDest, isMerchant); - Yếu tố thời gian (hour).

Kết quả này phù hợp với các phân tích EDA và khẳng định vai trò trung tâm của loại giao dịch và bối cảnh thời gian trong hành vi gian lận.

4.5.9 Kết quả thực nghiệm chi tiết với số liệu từ nghiên cứu

A. Tỷ lệ mất cân bằng và tham số xử lý:

- Tỷ lệ gian lận trong tập dữ liệu: 2.52% (8,213 mẫu gian lận trên tổng số 325,934 mẫu)
- Tham số `scale_pos_weight`: 38.69 (tỷ lệ giữa mẫu không gian lận và gian lận)

B. Mô hình XGBoost cơ sở (baseline):

Bảng 10: Kết quả mô hình XGBoost cơ sở

Chỉ số	Giá trị
ROC-AUC	0.9751
Precision (lớp gian lận)	0.2830
Recall (lớp gian lận)	0.8716
F1-Score (lớp gian lận)	0.4273
Accuracy	0.9411

Ma trận nhầm lẫn baseline:

$$CM_{\text{baseline}} = \begin{bmatrix} 59,916 & 3,628 \\ 211 & 1,432 \end{bmatrix}$$

C. Tối ưu siêu tham số với Optuna:

- Best ROC-AUC (5-fold CV): 0.97624
- Số trials: 30
- Tham số tối ưu:
 - Số lượng cây (`n_estimators`): 464
 - Độ sâu tối đa (`max_depth`): 8
 - Tốc độ học (`learning_rate`): 0.292
 - Tỷ lệ mẫu con (`subsample`): 0.961
 - Tỷ lệ đặc trưng (`colsample_bytree`): 0.933
 - Regularization L1 (`reg_alpha`): 7.626
 - Regularization L2 (`reg_lambda`): 7.797

D. So sánh chiến lược resampling:

Bảng 11: Hiệu suất các phương pháp resampling cho XGBoost

Phương pháp	ROC-AUC	F1-Score
SMOTE	0.9710	0.4905
SMOTE-ENN	0.9710	0.4707
SMOTE-Tomek	0.9712	0.4891
Oversampling	0.9715	0.3571
Undersampling	0.9711	0.3474

E. Phân tích ngưỡng phân loại:

Bảng 12: Ảnh hưởng của ngưỡng đến hiệu suất XGBoost

Threshold	Recall	Precision	F1-Score
0.10	0.9416	0.1353	0.2365
0.30	0.8472	0.3027	0.4460
0.50	0.7742	0.4961	0.6047
0.8257 (tối ưu)	0.6506	0.8198	0.7255
0.1974 (recall cao)	0.9002	0.2024	0.3305

F. Kết quả mô hình cuối cùng (XGBoost + SMOTE + Tuning):

Bảng 13: Đánh giá chi tiết mô hình XGBoost tối ưu

Chỉ số	Giá trị
ROC-AUC	0.9716
PR-AUC	0.7635
Precision (lớp gian lận)	0.8198
Recall (lớp gian lận)	0.6506
F1-Score (lớp gian lận)	0.7255
Accuracy	0.9876

Ma trận nhầm lẫn mô hình cuối:

$$CM_{\text{final}} = \begin{bmatrix} 63,309 & 235 \\ 574 & 1,069 \end{bmatrix}$$

G. Phân tích đặc trưng quan trọng:

Bảng 14: Top 5 đặc trưng quan trọng nhất - XGBoost

Đặc trưng	Importance	Mô tả
num_isCustomerDest	0.2331	Tài khoản đích là khách hàng
cat_type_PAYMENT	0.1820	Loại giao dịch thanh toán
cat_type_TRANSFER	0.1788	Loại giao dịch chuyển khoản
num_isMerchant	0.1374	Tài khoản đích là merchant
cat_type_CASH_OUT	0.1029	Loại giao dịch rút tiền

4.5.10 Tổng kết mô hình XGBoost

XGBoost là mô hình đạt hiệu suất cao nhất trong đề tài, với F1-score vượt trội so với Logistic Regression và Random Forest. Nhờ cơ chế boosting, regularization và khả năng xử lý dữ liệu mất cân bằng, XGBoost cho thấy khả năng mô hình hóa hành vi gian lận tín dụng một cách hiệu quả và linh hoạt. Đây là cơ sở để lựa chọn XGBoost làm mô hình đề xuất cho bài toán phát hiện gian lận trong phạm vi nghiên cứu của đề tài.

4.6 Dự đoán trên dữ liệu mới và mô phỏng triển khai mô hình

4.6.1 Mục tiêu và tập dữ liệu dự đoán

Sau khi lựa chọn được mô hình XGBoost tối ưu với hiệu năng cao nhất, nhóm tiến hành xây dựng một pipeline dự đoán độc lập nhằm mô phỏng kịch bản triển khai mô hình trong thực

tế. Mục tiêu của bước này là đánh giá khả năng tổng quát hóa của mô hình trên một tập dữ liệu hoàn toàn mới, chưa từng xuất hiện trong quá trình huấn luyện, xác thực hay kiểm tra.

Tập dữ liệu dự đoán được trích xuất từ tập dữ liệu PaySim gốc, gồm 50.000 giao dịch, không trùng lặp với 300.000 giao dịch đã sử dụng cho quá trình train/validation/test. Việc tách dữ liệu được thực hiện theo chỉ số dòng (hoặc theo mốc thời gian step), đảm bảo không xảy ra hiện tượng rò rỉ dữ liệu (data leakage).

Trong tập dữ liệu dự đoán, nhãn gian lận `isFraud` không được sử dụng trong quá trình suy luận, phản ánh đúng bối cảnh triển khai thực tế khi hệ thống cần đưa ra cảnh báo cho các giao dịch chưa được gán nhãn.

4.6.2 Quy trình dự đoán (Prediction Pipeline)


Pipeline dự đoán được thiết kế tách biệt hoàn toàn với pipeline huấn luyện, tuân theo nguyên tắc stateless preprocessing, bao gồm các bước chính sau:

1. **Nạp dữ liệu đầu vào** từ file dữ liệu mới.
2. **Tiền xử lý và xây dựng đặc trưng** theo đúng quy trình đã sử dụng khi huấn luyện mô hình, bao gồm:
 - Biến đổi log cho giá trị giao dịch (`log_amount`);
 - Rời rạc hóa yếu tố thời gian (`hour`, `day`);
 - Trích xuất vai trò tài khoản (`isMerchant`, `isCustomerDest`);
 - Giữ nguyên các đặc trưng ngưỡng cảnh như loại giao dịch (`type`).
3. **Nạp mô hình XGBoost** đã huấn luyện cùng với ngưỡng phân loại tối ưu được xác định trước đó.
4. **Dự đoán xác suất gian lận** cho từng giao dịch và gán nhãn gian lận dựa trên ngưỡng đã chọn.
5. **Xuất kết quả dự đoán**, bao gồm xác suất gian lận và cờ cảnh báo gian lận, phục vụ cho các bước phân tích và triển khai tiếp theo.

Quy trình này mô phỏng chính xác cách một mô hình phát hiện gian lận được tích hợp vào hệ thống vận hành thực tế, trong đó mô hình chỉ thực hiện suy luận (inference) trên dữ liệu mới mà không cần huấn luyện lại.

4.6.3 Kết quả dự đoán và phân tích


Kết quả dự đoán trên tập dữ liệu 50.000 giao dịch cho thấy mô hình XGBoost duy trì được hành vi dự đoán ổn định và hợp lý trên dữ liệu mới. Cụ thể, tỷ lệ giao dịch bị gán cờ gian lận vào khoảng 2.1%, gần sát với tỷ lệ gian lận thực tế trong tập dữ liệu PaySim (khoảng 2.5%).



Hình 4.6: Tỷ lệ giao dịch được mô hình XGBoost gán cờ gian lận trên tập dữ liệu dự đoán mới.

Ý nghĩa học thuật: Biểu đồ cho thấy mô hình không dự đoán dư thừa gian lận, không bị collapse về một lớp duy nhất, và không có dấu hiệu overfitting rõ rệt trên dữ liệu mới.

Bên cạnh đó, phân phối xác suất gian lận cho thấy phần lớn các giao dịch có xác suất rất thấp, trong khi chỉ một tỷ lệ nhỏ giao dịch có xác suất cao, tạo thành phân phối lệch phải với đuôi dài – một đặc điểm phù hợp với bản chất hiếm gặp của gian lận tài chính.



Hình 4.7: Phân phối xác suất gian lận do mô hình XGBoost dự đoán trên dữ liệu mới.

Ý nghĩa học thuật: Mô hình thể hiện khả năng phân biệt rủi ro liên tục, không chỉ dừng lại ở phân loại nhị phân cứng. Điều này phù hợp cho các chiến lược triển khai đa ngưỡng trong thực tế, cho phép điều chỉnh mức độ cảnh báo theo từng mức rủi ro cụ thể.

4.6.4 Nhận xét và hàm ý triển khai

Kết quả dự đoán trên dữ liệu mới cho thấy mô hình XGBoost có khả năng tổng quát hóa tốt, duy trì tỷ lệ cảnh báo hợp lý và phân phối xác suất phù hợp với đặc điểm của bài toán gian lận tín dụng. Việc sử dụng ngưỡng phân loại tối ưu cho phép cân bằng giữa độ tin cậy của cảnh báo và khả năng phát hiện gian lận, đồng thời tạo điều kiện để điều chỉnh linh hoạt theo các yêu cầu nghiệp vụ khác nhau.

Pipeline dự đoán được xây dựng độc lập với quá trình huấn luyện, cho phép mô hình sẵn sàng tích hợp vào các hệ thống phát hiện gian lận trong môi trường thực tế, nơi dữ liệu liên tục được cập nhật và nhãn gian lận không có sẵn tại thời điểm ra quyết định. Điều này khẳng định tính khả thi và hiệu quả của giải pháp trong các tình huống triển khai thực tế.

5 CHƯƠNG 5. KẾT QUẢ THỰC NGHIỆM VÀ ĐÁNH GIÁ MÔ HÌNH

5.1 Phân tích kết quả thực nghiệm từng mô hình

5.1.1 Mô hình Logistic Regression: Nền tảng phân tách tuyến tính

Mô hình Logistic Regression được triển khai như một baseline nhằm đánh giá khả năng phân tách tuyến tính của không gian đặc trưng. Kết quả thực nghiệm cho thấy mô hình đạt giá trị ROC-AUC là **0.9667**, thể hiện khả năng phân biệt tương đối tốt giữa hai lớp trên mặt phẳng

ROC. Tuy nhiên, khi xem xét các thước đo nhạy cảm với hiện tượng mất cân bằng dữ liệu, những hạn chế cố hữu của mô hình tuyến tính trở nên rõ rệt.

Bảng 15: Kết quả đánh giá chi tiết mô hình Logistic Regression

Chỉ số đánh giá	Giá trị
ROC-AUC (Area Under ROC Curve)	0.9667
PR-AUC (Area Under Precision-Recall Curve)	0.7321
Precision (Lớp gian lận)	0.5707
Recall (Lớp gian lận)	0.5648
F1-Score (Lớp gian lận)	0.5678
Độ chính xác tổng quát (Accuracy)	0.9858

Nhận xét chính từ kết quả trên cho thấy mô hình có xu hướng **thiên về Recall** (0.5648) hơn là Precision (0.5707), dẫn đến số lượng false positives (FP) tương đối cao. Điều này phù hợp với đặc điểm của mô hình tuyến tính khi giả định mối quan hệ đơn điệu giữa các biến đầu vào và biến mục tiêu, trong khi thực tế hành vi gian lận thường xuất hiện dưới dạng các **tương tác phi tuyến phức tạp** giữa nhiều yếu tố (ví dụ: sự kết hợp giữa loại giao dịch TRANSFER, thời điểm giao dịch ban đêm và sự thay đổi đột ngột của số dư tài khoản). Giá trị PR-AUC ở mức trung bình (0.7321) củng cố nhận định rằng mô hình gặp khó khăn trong việc duy trì độ chính xác ở các ngưỡng Recall cao – vốn là yêu cầu thiết yếu trong bài toán phát hiện gian lận.

5.1.2 Mô hình Random Forest: Khai thác quan hệ phi tuyến và tương tác đặc trưng

Nhằm khắc phục hạn chế của mô hình tuyến tính, mô hình Random Forest được áp dụng để khai thác các mối quan hệ phi tuyến và tương tác giữa các đặc trưng thông qua cơ chế ensemble của nhiều cây quyết định. Kết quả thu được cho thấy sự cải thiện đáng kể, đặc biệt trên phương diện Precision.

Bảng 16: Kết quả đánh giá chi tiết mô hình Random Forest sau tối ưu

Chỉ số đánh giá	Giá trị
ROC-AUC (Area Under ROC Curve)	0.9664
PR-AUC (Area Under Precision-Recall Curve)	0.7489
Precision (Lớp gian lận)	0.7682
Recall (Lớp gian lận)	0.6372
F1-Score (Lớp gian lận)	0.6966
Độ chính xác tổng quát (Accuracy)	0.9860

So với Logistic Regression, Random Forest đã nâng Precision lên **34.6%** (từ 0.5707 lên 0.7682) và F1-Score lên **22.7%** (từ 0.5678 lên 0.6966). Sự cải thiện này xuất phát từ khả năng của Random Forest trong việc tự động học các quy tắc phân lớp phức tạp, chẳng hạn như các điều kiện kết hợp giữa biến phân loại **type** và biến số **amount**. Phân tích tầm quan trọng đặc trưng (Feature Importance) tiết lộ rằng biến **cat_type_TRANSFER** đóng góp tới 38.01% tầm quan trọng, theo sau là các biến thời gian **num_hour** (13.27%) và **num_day** (12.23%). Điều này cho thấy mô hình đã nhận diện được tính chất **chu kỳ thời gian** của hành vi gian lận – một khía cạnh mà mô hình tuyến tính đã bỏ qua. Việc sử dụng kỹ thuật SMOTE kết hợp tối ưu siêu tham số bằng Optuna đã giúp kiểm soát hiện tượng overfitting và cân bằng hiệu quả giữa Precision và Recall.

5.1.3 Mô hình XGBoost: Tối ưu hiệu năng với Gradient Boosting

Để đạt được hiệu năng tối ưu, mô hình XGBoost – một biến thể nâng cao của Gradient Boosting – được triển khai với quy trình tối ưu toàn diện bao gồm điều chỉnh `scale_pos_weight`, áp dụng SMOTE, tinh chỉnh siêu tham số bằng Optuna và tối ưu ngưỡng phân lớp. Kết quả cuối cùng cho thấy XGBoost vượt trội so với hai mô hình trước trên hầu hết các thước đo then chốt.

Bảng 17: Kết quả đánh giá chi tiết mô hình XGBoost sau tối ưu toàn diện

Chỉ số đánh giá	Giá trị
ROC-AUC (Area Under ROC Curve)	0.9716
PR-AUC (Area Under Precision-Recall Curve)	0.7635
Precision (Lớp gian lận)	0.8198
Recall (Lớp gian lận)	0.6506
F1-Score (Lớp gian lận)	0.7255
Độ chính xác tổng quát (Accuracy)	0.9860

Mô hình XGBoost đạt được F1-Score cao nhất là **0.7255**, thể hiện sự cân bằng tối ưu giữa Precision (0.8198) và Recall (0.6506). So với baseline là Logistic Regression, XGBoost cải thiện Precision lên **43.6%** và F1-Score lên **27.8%**. So với Random Forest, mặc dù sự chênh lệch ROC-AUC là không đáng kể, XGBoost thể hiện ưu thế rõ rệt ở PR-AUC (0.7635 so với 0.7489), một thước đo quan trọng hơn trong bối cảnh dữ liệu mất cân bằng. Ưu thế của XGBoost có thể được lý giải qua ba yếu tố chính: (1) Cơ chế **gradient boosting** cho phép mỗi cây mới tập trung khắc phục sai sót còn lại của các cây trước, dẫn đến quá trình hội tụ hiệu quả hơn; (2) Hàm mục tiêu được tích hợp sẵn các thành phần **regularization** (L1/L2) giúp kiểm soát độ phức tạp mô hình và giảm thiểu overfitting; (3) Khả năng xử lý mất cân bằng dữ liệu thông qua tham số `scale_pos_weight` và hỗ trợ tích hợp các kỹ thuật resampling.

5.2 So sánh định lượng và phân tích hiệu năng tổng thể

Để có cái nhìn toàn diện, Bảng 18 tổng hợp kết quả của cả ba mô hình trên cùng một tập kiểm tra.

Bảng 18: So sánh toàn diện hiệu năng ba mô hình học máy

Mô hình	ROC-AUC	PR-AUC	Precision	Recall	F1-Score
Logistic Regression	0.9667	0.7321	0.5707	0.5648	0.5678
Random Forest	0.9664	0.7489	0.7682	0.6372	0.6966
XGBoost	0.9716	0.7635	0.8198	0.6506	0.7255

Phân tích số liệu cho thấy một quy luật rõ ràng: khi độ phức tạp và khả năng biểu diễn của mô hình tăng lên, hiệu năng trong việc phát hiện lớp thiểu số (gian lận) cũng được cải thiện tương ứng. Cụ thể:

- **Logistic Regression** cho thấy hiệu năng hạn chế với F1-Score thấp nhất (0.5678), phản ánh bản chất tuyến tính không phù hợp để nắm bắt các mẫu hình gian lận phức tạp.
- **Random Forest** tạo ra bước nhảy vọt về Precision (0.7682), chứng tỏ hiệu quả của việc chuyển sang mô hình phi tuyến. Tuy nhiên, Recall vẫn còn chỗ để cải thiện.

- **XGBoost** đạt được sự cân bằng tốt nhất, với cả Precision và Recall đều duy trì ở mức cao, dẫn đến F1-Score tối ưu (0.7255). Đây là kết quả của việc kết hợp ưu điểm từ cả hai mô hình trước: khả năng học các tương tác phi tuyến như Random Forest, và cơ chế tối ưu hóa tuần tự, kiểm soát độ phức tạp vượt trội.

Sự khác biệt về PR-AUC càng làm rõ ưu thế của XGBoost. Trong khi cả ba mô hình đều có ROC-AUC rất cao và chênh lệch nhỏ (từ 0.9664 đến 0.9716), PR-AUC – thước đo nhạy cảm hơn với lớp thiểu số – cho thấy XGBoost dẫn đầu với giá trị 0.7635, cao hơn Random Forest 1.95% và cao hơn Logistic Regression 4.29%. Điều này khẳng định XGBoost không chỉ phân biệt tốt giữa hai lớp nói chung, mà còn đặc biệt hiệu quả trong nhiệm vụ chính: duy trì độ chính xác cao khi cần phát hiện phần lớn các trường hợp gian lận (Recall cao).

5.3 Đánh giá ảnh hưởng của ngưỡng phân lớp và bàn luận

Một phân tích sâu về ảnh hưởng của ngưỡng phân lớp (decision threshold) được thực hiện trên mô hình XGBoost, cho thấy tính linh hoạt của mô hình trong việc đáp ứng các yêu cầu nghiệp vụ khác nhau.

Bảng 19: Ảnh hưởng của ngưỡng phân lớp đến hiệu năng mô hình XGBoost

Kịch bản / Ngưỡng	Recall	Precision	F1-Score	Mục tiêu nghiệp vụ
Ngưỡng thấp (0.1049)	0.9002	0.1770	0.2959	Ưu tiên tối đa hóa Recall, chấp nhận nhiều FP
Ngưỡng mặc định (0.5)	0.7742	0.4961	0.6047	Cân bằng tương đối giữa Precision và Recall
Ngưỡng tối ưu F1 (0.8257)	0.6506	0.8198	0.7255	Cân bằng tối ưu cho triển khai thực tế
Ngưỡng cao (0.9)	0.5000	0.9000	0.6429	Ưu tiên độ tin cậy cảnh báo (Precision cực cao)

Kết quả từ Bảng 19 minh họa rõ ràng sự đánh đổi (trade-off) kinh điển giữa Precision và Recall. Việc lựa chọn ngưỡng phụ thuộc hoàn toàn vào chiến lược quản lý rủi ro và nguồn lực của tổ chức tài chính:

- **Ngưỡng thấp (0.1049):** Phù hợp nếu chi phí của một giao dịch gian lận bị bỏ sót (False Negative) là cực kỳ cao, và tổ chức sẵn sàng đầu tư nguồn lực lớn để kiểm tra thủ công một số lượng lớn cảnh báo (khoảng 20% tổng giao dịch) để đảm bảo phát hiện tới 90% số vụ gian lận.
- **Ngưỡng tối ưu F1 (0.8257):** Được đề xuất cho triển khai thực tế. Với ngưỡng này, hệ thống đạt độ tin cậy cảnh báo trên 81%, đồng nghĩa với việc hơn 8/10 cảnh báo là chính xác. Điều này giảm thiểu đáng kể gánh nặng cho đội ngũ kiểm tra, trong khi vẫn phát hiện được 65% tổng số giao dịch gian lận. Đây là điểm cân bằng giữa hiệu quả phát hiện và tính khả thi về mặt vận hành.
- **Ngưỡng cao (0.9):** Phù hợp khi nguồn lực kiểm tra rất hạn chế và mục tiêu là chỉ can thiệp vào những trường hợp có xác suất gian lận cực kỳ cao, với độ chính xác cảnh báo lên tới 90%.

5.4 Kết luận chương và khuyến nghị

Tổng hợp kết quả thực nghiệm từ ba mô hình học máy cho bài toán phát hiện gian lận giao dịch tín dụng, có thể rút ra những kết luận sau:

1. **Tính phù hợp của kiến trúc mô hình:** Có sự tương quan rõ ràng giữa độ phức tạp/khả năng biểu diễn của mô hình và hiệu năng phát hiện lớp thiểu số. Mô hình tuyến tính (Logistic Regression) tỏ ra không đủ sức để nắm bắt bản chất phi tuyến và đa tương tác của hành vi gian lận, dẫn đến hiệu suất dưới mức tối ưu.
2. **Ưu thế của các mô hình ensemble phi tuyến:** Cả Random Forest và XGBoost đều chứng minh được hiệu quả vượt trội so với baseline. Trong đó, XGBoost thể hiện là mô hình mạnh mẽ nhất, đạt được sự cân bằng tối ưu giữa Precision và Recall (F1-Score = 0.7255) cũng như có PR-AUC cao nhất (0.7635), khẳng định ưu thế trong xử lý dữ liệu mất cân bằng.
3. **Tầm quan trọng của quy trình tối ưu hóa:** Hiệu năng vượt trội của XGBoost không chỉ đến từ bản thân thuật toán, mà còn là kết quả của một quy trình tối ưu hóa hệ thống, bao gồm xử lý mất cân bằng (SMOTE), tinh chỉnh siêu tham số (Optuna), và đặc biệt là việc tối ưu ngưỡng phân lớp dựa trên đường cong Precision-Recall.
4. **Tính linh hoạt cho triển khai thực tế:** Phân tích ngưỡng cho thấy mô hình XGBoost có thể được điều chỉnh linh hoạt để phù hợp với các chính sách quản trị rủi ro khác nhau, từ việc ưu tiên phát hiện tối đa đến việc ưu tiên độ tin cậy của cảnh báo.

Khuyến nghị triển khai: Dựa trên phân tích toàn diện, nghiên cứu đề xuất triển khai mô hình **XGBoost với ngưỡng phân lớp 0.8257** cho hệ thống phát hiện gian lận trong thực tế. Cấu hình này đảm bảo một sự cân bằng tối ưu: mỗi cảnh báo có độ tin cậy trên 81%, giảm thiểu chi phí kiểm tra sai, đồng thời vẫn phát hiện được khoảng 2/3 tổng số giao dịch gian lận. Để tiếp tục nâng cao hiệu năng, các hướng nghiên cứu tiếp theo có thể tập trung vào việc tích hợp thêm các nguồn dữ liệu bối cảnh (như lịch sử người dùng, địa điểm giao dịch), thử nghiệm các kiến trúc học sâu (Deep Learning), hoặc xây dựng hệ thống học trực tuyến (Online Learning) để thích ứng nhanh với các hình thức gian lận mới.

6 CHƯƠNG 6. KẾT LUẬN

6.1 Tổng kết

Trong đề tài này, nhóm chúng em đã nghiên cứu và triển khai một quy trình hoàn chỉnh ứng dụng Machine Learning cho bài toán phát hiện gian lận tín dụng dựa trên dữ liệu giao dịch tài chính PaySim. Quy trình nghiên cứu được xây dựng có hệ thống, bao gồm các bước từ phân tích khám phá dữ liệu (EDA), thiết kế và xây dựng đặc trưng dựa trên logic nghiệp vụ, đến huấn luyện, tối ưu và đánh giá các mô hình học máy.

Kết quả phân tích EDA cho thấy gian lận trong dữ liệu PaySim không phân bố ngẫu nhiên mà tập trung vào một số bối cảnh giao dịch cụ thể, đặc biệt là các giao dịch TRANSFER và CASH_OUT, các giao dịch có giá trị cao và các trường hợp xuất hiện bất thường trong cập nhật số dư. Bên cạnh đó, dữ liệu thể hiện rõ đặc điểm mất cân bằng nghiêm trọng, đặt ra yêu cầu cao đối với việc lựa chọn thước đo đánh giá và chiến lược huấn luyện mô hình.

Trên cơ sở đó, nhóm chúng em đã triển khai và so sánh ba mô hình Machine Learning tiêu biểu gồm Logistic Regression, Random Forest và XGBoost. Logistic Regression đóng vai trò là mô hình nền, giúp kiểm chứng khả năng phân tách tuyến tính và cung cấp khả năng diễn giải

tốt. Random Forest cải thiện đáng kể hiệu năng nhờ khả năng mô hình hóa các quan hệ phi tuyến và tương tác giữa các đặc trưng. XGBoost, với cơ chế boosting và regularization mạnh, cho thấy hiệu năng vượt trội nhất trên các thước đo quan trọng như F1-score và PR-AUC.

Thông qua việc tối ưu siêu tham số, xử lý mất cân bằng dữ liệu và điều chỉnh ngưỡng phân loại, đề tài đã chứng minh rằng hiệu năng mô hình không chỉ phụ thuộc vào thuật toán được lựa chọn, mà còn phụ thuộc mạnh mẽ vào cách thiết kế đặc trưng, chiến lược huấn luyện và cách đánh giá phù hợp với mục tiêu phát hiện gian lận. Trong phạm vi nghiên cứu, XGBoost được xác định là mô hình phù hợp nhất để đề xuất cho bài toán phát hiện gian lận tín dụng.

6.2 Hạn chế

Mặc dù đạt được các kết quả tích cực, đề tài vẫn tồn tại một số hạn chế nhất định. Trước hết, tập dữ liệu PaySim là dữ liệu mô phỏng, dù được xây dựng dựa trên dữ liệu thực tế nhưng vẫn chưa phản ánh đầy đủ các yếu tố phức tạp, nhiễu và biến động của các hệ thống tài chính thực. Do đó, khả năng tổng quát hóa của mô hình đối với dữ liệu ngân hàng thực tế cần được đánh giá thêm.

Thứ hai, đề tài tập trung vào các mô hình Machine Learning truyền thống và chưa xem xét các phương pháp học sâu hoặc các mô hình phát hiện bất thường nâng cao, vốn có thể khai thác tốt hơn các cấu trúc dữ liệu phức tạp hoặc mối quan hệ theo chuỗi thời gian. Ngoài ra, nghiên cứu chưa xét đến các yếu tố triển khai thực tế như xử lý thời gian thực, chi phí tính toán, khả năng mở rộng và các yêu cầu về bảo mật trong hệ thống vận hành.

Cuối cùng, việc chia dữ liệu huấn luyện và kiểm tra chủ yếu dựa trên cách chia ngẫu nhiên có phân tầng, chưa mô phỏng đầy đủ các kịch bản huấn luyện – kiểm tra theo trục thời gian, vốn rất quan trọng trong các hệ thống phát hiện gian lận thực tế.

6.3 Hướng phát triển

Từ các kết quả đạt được và những hạn chế đã nêu, đề tài mở ra một số hướng phát triển trong tương lai. Thứ nhất, nghiên cứu có thể được mở rộng bằng cách áp dụng và so sánh các mô hình học sâu như mạng nơ-ron sâu, LSTM hoặc Transformer nhằm khai thác tốt hơn yếu tố chuỗi thời gian và hành vi liên tiếp của các giao dịch.

Thứ hai, việc tích hợp các phương pháp phát hiện bất thường (anomaly detection) hoặc học bán giám sát có thể giúp phát hiện các dạng gian lận mới chưa từng xuất hiện trong dữ liệu huấn luyện. Ngoài ra, nghiên cứu trong tương lai có thể xem xét các chiến lược đánh giá theo thời gian (time-based validation) để phản ánh sát hơn bối cảnh vận hành thực tế.

Cuối cùng, để tăng tính ứng dụng, các mô hình có thể được nghiên cứu triển khai trong môi trường giả lập thời gian thực, kết hợp với các yếu tố chi phí, độ trễ và rủi ro vận hành, qua đó tiến gần hơn đến các hệ thống phát hiện gian lận trong thực tế của lĩnh vực tài chính – ngân hàng.

TÀI LIỆU THAM KHẢO

1. Dal Pozzolo, A., Bontempi, G., Snoeck, M., & Bontempi, G. *Adversarial drift detection in fraud detection*. IEEE Intelligent Systems.
2. Bahnsen, A. C., Aouada, D., & Ottersten, B. *Cost-sensitive decision trees for fraud detection*. Expert Systems with Applications.
3. Dal Pozzolo, A., Boracchi, G., Bontempi, G., & Snoeck, M. *Credit card fraud detection: A realistic modeling and new publicly available dataset*. IEEE.

4. Chen, T., & Guestrin, C. (2016). *XGBoost: A scalable tree boosting system*. In Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining.
5. Breiman, L. (2001). *Random forests*. Machine Learning, 45(1), 5–32.
6. Bishop, C. M. (2006). *Pattern Recognition and Machine Learning*. Springer.
7. Lightly.ai. (2023). *Mastering the F1 Score: A Practical Guide for Machine Learning Success*. Truy cập từ <https://www.lightly.ai/blog/f1-score>
8. Brownlee, J. (2021). *A Gentle Introduction to the Fbeta-Measure for Machine Learning*. Machine Learning Mastery. Truy cập từ <https://machinelearningmastery.com/fbeta-measure-for-machine-learning/>
9. Brownlee, J. (2021). *Algorithm Showdown: Logistic Regression vs. Random Forest vs. XGBoost on Imbalanced Data*. Machine Learning Mastery. Truy cập từ <https://machinelearningmastery.com/showdown-logistic-regression-vs-random-forest-vs-xgboost-on-imbalanced-data/>
10. Scikit-learn. (2023). *Probability calibration documentation*. Truy cập từ <https://scikit-learn.org/stable/modules/calibration.html>
11. Scikit-learn. (2023). *Ensemble methods documentation*. Truy cập từ <https://scikit-learn.org/stable/mo>